

Segmentation sémantique en télédétection



GRETSI 2027 — session plénière

Josiane ZERUBIA

Centre Inria d'Université Côte d'Azur, équipe AYANA

en collaboration avec Martina PASTORINO et Gabriele MOSER

Università di Genova, DITEN

1. Introduction
2. Classification statistique pixel à pixel
3. Méthodes discriminantes et à noyaux
4. Méthodes d'ensemble
5. Classification contextuelle
6. Modèles markoviens et bayésiens
7. Méthodes spectro-spatiales
8. Méthodes variationnelles
9. Apprentissage profond
10. Transformers et modèles de fondation
11. Conclusion

D'après M. PASTORINO, G. MOSER, J. ZERUBIA, « Segmentation sémantique en télédétection ». Le plan de l'exposé suit celui de l'article.


01

Introduction



De l'image à la carte thématique

- ▶ Associer à **chaque pixel** une étiquette d'un ensemble prédéfini de classes sémantiques [1] [2] [3] — terme imposé par l'essor de l'apprentissage profond (années 2010), mais problème étudié depuis des décennies sous les noms de *classification supervisée*, *pixel à pixel*, *contextuelle*
- ▶ Produit une **carte dense** : chaque pixel reçoit une interprétation — à distinguer de la segmentation « bas niveau », qui partitionne en régions homogènes *sans* leur associer de signification
- ▶ En télédétection : transformer les observations satellitaires en **cartes d'occupation et d'utilisation du sol**



(a) image aérienne



(b) carte de segmentation

Fig. 1 de l'article. Jeu de données Zeebruges (comité technique IADF de l'IEEE GRSS ; Académie royale militaire belge et ONERA).



Ce qui distingue la télédétection

- ▶ **Capteurs** hétérogènes : optique, radar à synthèse d'ouverture (RSO), LiDAR
- ▶ **Résolutions** spatiales très variables, acquisitions à **différentes dates**, **plusieurs modalités** combinées
- ▶ Scènes géographiques complexes, dont les propriétés varient selon les régions, les saisons et les conditions d'acquisition
- ▶ Conséquence : l'évolution du domaine **n'est pas** une simple adaptation des avancées de la vision par ordinateur
- ▶ C'est une convergence entre reconnaissance statistique des formes, traitement du signal et des images, modélisation probabiliste, morphologie mathématique, géométrie stochastique, analyse orientée objet et, récemment, apprentissage profond



Formalisation et fil directeur

$$I : \Omega \longrightarrow \mathbb{R}^d \quad \text{puis} \quad f : \Omega \longrightarrow \mathcal{C}$$

- ▶ Ω : domaine spatial ; d : nombre de variables — bande panchromatique, bandes multi- ou hyperspectrales, polarisations RSO, mesures LiDAR, indices spectraux, modèles numériques de terrain...
- ▶ $\mathcal{C}$: ensemble fini des classes sémantiques
- ▶ **Fil directeur de l'exposé** : une intégration progressive de niveaux croissants de contexte



02

Classification statistique pixel à pixel





Les premières approches (années 1970)

- ▶ Landsat (optique) et SeaSat (radar) créent le besoin de cartes d'occupation du sol automatiques [4] [5] [6]
- ▶ Chaque pixel est un vecteur d'observations $\mathbf{x} = (x_1, \dots, x_d)^T$: réponses radiométriques, intensités RSO, indices, données auxiliaires [1]

$$\hat{\omega} = \arg \max_{\omega_i} P(\omega_i | \mathbf{x})$$

- ▶ Sous hypothèse gaussienne multivariée : **classifieur MAP**, dit de manière informelle « maximum de vraisemblance » (MLC)
- ▶ Méthode de référence pendant plusieurs décennies : interprétation probabiliste simple, coût modéré, performances satisfaisantes [2] [3] [7]




Deux limites structurelles

- ▶ **Malédiction de la dimension** (phénomène de Hughes, décrit dès 1968) [8]
 - plus de variables spectrales $\neq$ meilleures performances lorsque le nombre d'échantillons d'apprentissage reste limité
 - les signatures spectrales seules ne suffisent pas
- ▶ **Hypothèse d'indépendance des observations**
 - chaque pixel est décidé isolément, sans exploiter son voisinage
 - or les objets géographiques sont fortement corrélés spatialement : parcelle agricole, forêt, zone urbaine, réseau routier
- ▶ Conséquence : cartes bruitées, effet « **poivre et sel** », d'autant plus marqué que la résolution spatiale augmente

L'effet « poivre et sel »



(a) image IKONOS, 4 m, fausses couleurs



(b) classification pixel à pixel

- La décision ne dépend plus seulement de la radiométrie d'un pixel : il faut son **environnement spatial**
- Le problème cesse d'être une classification spectrale pour devenir un problème d'**interprétation spatiale des scènes** [9] [10] [11]

Fig. 2 (a)–(b) de l'article. Image IKONOS, 4 m, 3 bandes, fausses couleurs (infrarouge voisin, rouge, bleu) ; carte d'après [12].

03

Méthodes discriminantes et à noyaux



Estimer la frontière plutôt que la distribution

- ▶ À partir de la fin des années 1990 : estimer **directement les frontières de décision** plutôt que la loi des observations
- ▶ Réponse à deux difficultés : hypothèses gaussiennes peu réalistes, dimension élevée des données
- ▶ **Machines à vecteurs de support** (SVM), issues de la théorie de l'apprentissage statistique [13] [14]
 - principe de **maximisation de la marge** entre classes
 - excellente généralisation même lorsque le nombre d'échantillons d'apprentissage est faible devant la dimension

Noyaux : la non-linéarité sans perdre la convexité

- ▶ Les méthodes à noyaux étendent le cadre aux problèmes non linéaires tout en conservant une **formulation convexe** [15]
- ▶ Années 2000 : les SVM deviennent l'un des classifieurs les plus utilisés en télédétection — multispectral, hyperspectral, multisources
- ▶ Développement de noyaux adaptés aux observations géospatiales [16] [17]
- ▶ **Mais** : les SVM améliorent la *fonction de décision*, pas la représentation — appliqués aux vecteurs d'observations, ils restent des classifieurs **pixel à pixel**
- ▶ Deux directions de recherche évoluent alors en parallèle : *nouveaux classifieurs* et *représentations spatiales plus riches*

04

Méthodes d'ensemble



Forêts aléatoires

- ▶ Combiner plusieurs classifieurs pour gagner en robustesse et en généralisation : **apprentissage d'ensemble**
- ▶ **Forêts aléatoires** : arbres de décision appris sur des sous-ensembles aléatoires *des observations* et *des variables*, agrégés par vote majoritaire [18]
- ▶ Limitent le surapprentissage tout en modélisant des relations non linéaires
- ▶ En pratique : peu de réglages, robustes au bruit, supportent un grand nombre de variables, fournissent des mesures d'**importance des variables**
- ▶ Multispectral et hyperspectral [19], puis occupation du sol, détection de changements, fusion multisources [20]



Bilan de l'ère « pixel »

- ▶ Méthodes discriminantes et d'ensemble : gains nets **sur le classifieur**
- ▶ Elles restent **indépendantes de la représentation** — spectrale, texturale, morphologique ou spectro-spatiale
- ▶ La limite fondamentale demeure : **l'organisation spatiale de la scène n'est pas prise en compte explicitement**
- ▶ Deux réponses complémentaires vont structurer la suite :
 - régulariser les **étiquettes** — contextuel, markovien, variationnel (§5, §6, §8)
 - enrichir les **descripteurs** — spectro-spatial, orienté objet (§7)

05

Classification contextuelle






Trois niveaux de contexte

- ▶ Dès les années 1980–1990 : un pixel a davantage de chances d'appartenir à la classe de ses voisins immédiats qu'à une autre [3]
- ▶ **Contexte local** — interactions entre pixels voisins, fenêtres de taille limitée [21] [22]
- ▶ **Contexte régional** — texture, forme, taille, homogénéité des régions segmentées ; annonce l'analyse orientée objet [23]
- ▶ **Contexte global** — organisation générale de la scène, relations entre objets, connaissances a priori sur leur disposition
- ▶ Hiérarchie structurante jusqu'aux architectures profondes contemporaines [24] [25] [26]


L'apport mesurable du contexte



(a) image IKONOS



(b) pixel à pixel



(c) contextuelle

- Gains nets en multispectral, multitemporel et multisources [27] [28]
- Formulations probabilistes explicites des interactions ; fusion optique / radar / texture [11]
- La classification n'est plus une suite de décisions indépendantes : les étiquettes doivent être estimées **conjointement**

Fig. 2 de l'article. Image IKONOS, 4 m, 3 bandes, fausses couleurs (infrarouge voisin, rouge, bleu) ; cartes d'après [12].

06

Modèles markoviens et bayésiens



Les champs de Markov : la première formalisation

- ▶ Les étiquettes ne sont plus indépendantes : ce sont des variables aléatoires définies sur un **graphe de voisinage** [9] [10] [29]
- ▶ Hypothèses de Markov et équivalence champs de Markov / distributions de Gibbs

$$\hat{Y} = \arg \max_Y P(Y | X) \quad \Longleftrightarrow \quad \hat{Y} = \arg \min_Y U(Y | X)$$

- ▶ X : les observations, Y : les étiquettes à estimer
- ▶ Le théorème de Bayes transforme l'estimation MAP en une **minimisation d'énergie**



Attache aux données + régularisation

$$U(Y | X) = U_d(Y | X) + \beta U_r(Y | X)$$

- ▶ U_d : **attache aux données**, dérivée de la vraisemblance
- ▶ U_r : **régularisation spatiale**, favorise la cohérence entre pixels voisins
- ▶ β : compromis fidélité / régularité
- ▶ Voisinages du 1^{er} ou du 2^d ordre ; les potentiels de clique pénalisent les changements de classe entre pixels adjacents [29]




Fig. 3 de l'article : voisinages entre pixels dans une grille et cliques associées, d'après [29].



Optimiser : un problème difficile

- ▶ Trouver la configuration optimale est un problème d'optimisation combinatoire difficile $\Rightarrow$ stratégies **sous-optimales**
- ▶ Modes conditionnels itérés (**ICM**), **recuit simulé** [30], échantillonneur de **Gibbs** [9]
- ▶ **Coupes de graphes** [31], **propagation de croyance avec boucles** [32]
- ▶ Domaines d'application : cohérence spatiale des classifications, segmentation multisource, restauration, détection de changements, fusion optique / radar / LiDAR [11] [33] [34]
- ▶ Au-delà des applications : une **formulation probabiliste générale de la régularisation spatiale**



Des MRF aux CRF

- ▶ Les champs conditionnels aléatoires représentent directement $P(Y | X)$ plutôt que la loi jointe [35]
- ▶ Ils facilitent l'usage de **caractéristiques discriminantes complexes** et s'intègrent naturellement à l'apprentissage supervisé
- ▶ **CRF entièrement connectés** : contours des objets mieux préservés [36]
- ▶ Intégration aux réseaux profonds : modules de raffinement, **couches différentiables** [37] — cadres markoviens hiérarchiques et CRF appris [38] [39] [40] [41]
- ▶ **L'idée qui traverse tout le domaine** : une carte d'occupation du sol doit être compatible avec les observations locales et avec l'organisation spatiale de la scène

07

Méthodes spectro-spatiales



Enrichir la représentation, pas les étiquettes

- ▶ Les modèles contextuels régularisent les **étiquettes** ; ici on enrichit les **descripteurs** *avant* la classification [5]
- ▶ Moteur : montée en résolution spatiale et spectrale des capteurs
 - une même classe présente une forte variabilité spectrale
 - des objets différents ont parfois des signatures très proches
- ▶ Texture, forme, taille, organisation spatiale et relations de voisinage deviennent **aussi discriminantes que les valeurs spectrales** [42]

Morphologie mathématique



érosion



image originale RVB



dilatation

- ▶ Statistiques locales et descripteurs texturaux [21]
- ▶ Opérateurs de morphologie mathématique — érosion, dilatation et leurs compositions [43] [44]

Fig. 4 de l'article : érosion (à gauche) et dilatation (à droite) de l'image satellite originale RVB (au centre).



Profils morphologiques et profils d'attributs

- ▶ **Profils morphologiques étendus** (EMP) [45] puis **profils d'attributs** [46] : décrire simultanément les propriétés spectrales et la structure spatiale **à plusieurs échelles**
- ▶ Références pour l'hyperspectral et la très haute résolution
- ▶ Associés aux SVM : performances remarquables [16] [47] — mais le principe est général (forêts aléatoires, réseaux de neurones...)
- ▶ Réduction de dimension, méthodes fondées sur les sous-espaces, fusion multisources [48] [49]
- ▶ Utiliser les **régions segmentées** comme unités d'analyse plutôt que les pixels : cohérence spatiale accrue, bruit réduit [50]

08

Méthodes variationnelles





Segmenter en minimisant une énergie

- ▶ Fin des années 1980, en parallèle des champs de Markov : **pas de loi de probabilité explicite sur les étiquettes**, mais la recherche de la partition qui réalise le meilleur compromis entre fidélité aux observations et régularité [29] [51] [52]
- ▶ **Contours actifs** : les frontières sont des courbes déformables évoluant sous l'action [52] [53]
 - de *forces internes* — régularité du contour
 - de *forces externes* — dérivées de l'information de l'image
- ▶ Une représentation **explicite** des contours, et le point de départ d'une large famille de méthodes par minimisation d'énergie



La fonctionnelle de Mumford–Shah


$$E(u, K) = \int_{\Omega} (u - I)^2 dx + \mu \int_{\Omega \setminus K} |\nabla u|^2 dx + \nu |K|$$

- ▶ u : image reconstruite, I : image observée, K : ensemble des discontinuités (les contours) [51]
- ▶ $\mu > 0$: douceur de la solution à l'intérieur des régions ; $\nu > 0$: pondération de la mesure des contours
- ▶ Trois termes, un principe : **fidélité** aux observations, **régularité** intra-région, **complexité géométrique** des contours
- ▶ L'un des modèles variationnels les plus influents en traitement d'images



Robustesse numérique et applications

- ▶ **Surfaces de niveau** : contours représentés implicitement, changements de topologie gérés automatiquement [54]
- ▶ **Modèles régionaux** : statistiques des régions plutôt que gradients seuls — robustes au bruit et au faible contraste [55]
- ▶ En télédétection : segmentation optique haute résolution, restauration, fusion, extraction d'objets ; classification et restauration unifiées dans une même fonctionnelle [52]
- ▶ **Convergence** : bayésien, champs de Markov, variationnel et formulations sur graphes sont différentes expressions d'un même principe — **attache aux données + régularisation**



(a) image SPOT (b) segmentation

Fig. 5 de l'article. (a) image satellitaire SPOT © CNES ; (b) carte de segmentation obtenue par la méthode variationnelle de [52].

09

Apprentissage profond






2012 : la bascule

- ▶ ILSVRC : AlexNet démontre une amélioration spectaculaire en classification d'images naturelles [56]
- ▶ On **apprend** des représentations hiérarchiques directement à partir des données, sans conception manuelle de descripteurs spectraux, texturaux ou géométriques
- ▶ La performance dépend désormais de la capacité du réseau à apprendre **conjointement** une représentation pertinente *et* la fonction de décision
- ▶ Transposition rapide à la télédétection : représentations plus discriminantes, **transfert** de modèles pré-entraînés sur les grandes bases d'images naturelles [57] [58]
- ▶ Les approches spectro-spatiales passent de représentations *conçues* à des représentations *appries*

Prédiction dense : FCN et encodeur-décodeur

- **FCN** : suppression des couches entièrement connectées au profit d'opérations convolutionnelles $\Rightarrow$ prédiction dense à l'échelle du pixel, apprise de bout en bout [59]
- **U-Net** : encodeur-décodeur dont les *connexions de saut* réinjectent la localisation perdue au sous-échantillonnage — contours et petits objets [61]
- Applications : occupation du sol, extraction de bâtiments, de routes, de réseaux hydrographiques [62] [63] [64]



architecture d'une FCN

Fig. 6 de l'article : architecture d'une FCN appliquée aux images aériennes de la base ISPRS 2D Semantic Labeling Challenge (Potsdam), d'après [60].



Contexte, échelles, modalités

- ▶ **Réseaux résiduels** : apprendre des modèles plus profonds en limitant la disparition du gradient [65]
- ▶ **DeepLab** : convolutions dilatées et agrégation multi-échelle (ASPP) — augmenter le champ réceptif *sans* dégrader la résolution des prédictions [66] [67]
- ▶ **Pyramides de caractéristiques** : objets de tailles très variables [68] — décisif en télédétection, où une même scène contient véhicules, bâtiments, parcelles et massifs forestiers
- ▶ **Multimodalité** : apprendre des représentations communes à partir de l'optique, du RSO, du LiDAR, des modèles numériques de terrain et de données géographiques auxiliaires [62] [69]

Ce que l'apprentissage profond ne supprime pas

- ▶ Contexte spatial, représentation multi-échelle, fusion de données, hiérarchie des objets : **reformulés** dans un cadre d'apprentissage de bout en bout, non abandonnés
- ▶ Limites persistantes des réseaux convolutifs :
 - annotations pixel à pixel **coûteuses**, particulièrement en télédétection
 - **généralisation** limitée entre capteurs, régions géographiques et modalités d'acquisition
 - difficulté à modéliser les dépendances spatiales à **très longue portée**
- ▶ Ces limites ouvrent la voie aux mécanismes d'attention, puis aux modèles de fondation géospatiaux

10

Transformers et modèles de fondation





L'attention en segmentation

- ▶ Développés pour le traitement du langage, les « transformers » modélisent directement les relations entre **éléments distants** d'une séquence [70] ; leur adaptation à la vision ouvre une nouvelle étape [71]
- ▶ **Swin Transformer** [72] et **SegFormer** [73] : combiner une représentation *hiérarchique* de l'image et une modélisation *globale* du contexte
- ▶ Particulièrement pertinent en télédétection : l'identification d'un bâtiment, d'une route ou d'une parcelle ne repose pas seulement sur l'apparence locale, mais sur son **organisation au sein de la scène**




Apprendre sans annotations

- ▶ L'**apprentissage auto-supervisé** devient un axe majeur de recherche
- ▶ Les **autoencodeurs masqués** montrent qu'il est possible d'apprendre des représentations visuelles riches à partir de grandes quantités de données **non annotées** [74]
- ▶ Réponse directe à un déséquilibre propre au domaine :
 - les archives satellitaires sont **abondantes**
 - les annotations pixel à pixel restent **rares et coûteuses**



Modèles de fondation géospatiaux

- ▶ Pré-entraînés sur de très grands volumes, puis adaptés : classification, segmentation, détection d'objets, détection de changements, fusion multimodale [75] [76] [77] [78] [79]
- ▶ Objectif : des représentations **génériques**, transférables entre capteurs, régions géographiques et applications
- ▶ **Coût** du pré-entraînement : calcul, matériel, énergie $\Rightarrow$ empreinte environnementale et accessibilité pour la communauté scientifique
- ▶ Pas une rupture : les mêmes questions — hétérogénéité, contexte spatial, généralisation, modalités complémentaires — sont désormais **appries** plutôt que **construites**



principe général d'un modèle de fondation géospatial

Fig. 7 de l'article : principe général d'un modèle de fondation géospatial.

11

Conclusion



Une histoire non linéaire

- ▶ Pas une trajectoire allant simplement des classifieurs statistiques aux réseaux profonds, mais la **convergence de plusieurs traditions** : classification statistique, méthodes à noyaux, méthodes d'ensemble, modèles contextuels, champs de Markov, méthodes variationnelles, géométrie stochastique, apprentissage profond, modèles de fondation
- ▶ Une lecture unifiée : l'**intégration progressive de niveaux croissants de contexte**



- ▶ Un principe récurrent : **attache aux données + régularisation** — des champs de Markov aux fonctions de perte des réseaux profonds

Défis ouverts

- ▶ Généralisation géographique
- ▶ Manque d'annotations
- ▶ Fusion optique / radar / LiDAR
- ▶ Prise en compte de la temporalité
- ▶ Interprétabilité des modèles
- ▶ Robustesse opérationnelle
- ▶ La segmentation sémantique en télédétection demeure un **domaine ouvert**, à l'intersection du traitement du signal et des images, de la modélisation probabiliste, de la géométrie, de la vision par ordinateur et de l'intelligence artificielle — dans un contexte géospatial

Merci.





Crédits des figures

Toutes les illustrations sont reprises de M. PASTORINO, G. MOSER, J. ZERUBIA, « Segmentation sémantique en télédétection ».

- ▶ **Fig. 1** — jeu de données *Zeebruges*, publié par le comité technique d'analyse d'image et de fusion de données (IADF) de l'IEEE GRSS ; images et vérité terrain fournies par l'Académie royale militaire belge et l'ONERA — Laboratoire aérospatial français.
- ▶ **Fig. 2** — image satellitaire IKONOS, 4 m, 3 bandes, composition en fausses couleurs (infrarouge voisin — rouge — bleu) ; cartes de segmentation d'après [12].
- ▶ **Fig. 3** — voisinages du premier et du second ordre dans une grille, d'après [29].
- ▶ **Fig. 4** — érosion et dilatation d'une image satellite RVB.
- ▶ **Fig. 5** — image satellitaire SPOT © CNES ; carte de segmentation obtenue par la méthode variationnelle de [52].
- ▶ **Fig. 6** — architecture d'une FCN appliquée aux images aériennes de la base ISPRS *2D Semantic Labeling Challenge* (Potsdam), d'après [60].
- ▶ **Fig. 7** — principe général d'un modèle de fondation géospatial.

Références

- [1] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973.
- [2] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978.
- [3] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986.
- [4] R. SCHOWENGERDT. *Remote Sensing : Models and Methods for Image Processing*. Academic Press, 2007.
- [5] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003.
- [6] F. ULABY et D. LONG. *Microwave Radar and Radiometric Remote Sensing*. 1^{re} éd. Artech House, 2015.
- [7] P. M. MATHER. *Computer Processing of Remotely-Sensed Images*. Wiley, 2004.
- [8] G. HUGHES. « On the mean accuracy of statistical pattern recognizers ». In : *IEEE Transactions on Information Theory* 14.1 (1968), p. 55-63.
- [9] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 6.6 (1984), p. 721-741.
- [10] J. BESAG. « On the statistical analysis of dirty pictures ». In : *Journal of the Royal Statistical Society : Series B* 48.3 (1986), p. 259-302.
- [11] A. H. S. SOLBERG, T. TAXT et A. K. JAIN. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Transactions on Geoscience and Remote Sensing* 34.1 (1996), p. 100-113.
- [12] G. MOSER, S. B. SERPICO et J. A. BENEDIKTSSON. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proceedings of the IEEE* 101.3 (2013), p. 631-651.
- [13] V. N. VAPNIK. *Statistical Learning Theory*. Wiley, 1998.
- [14] C. CORTES et V. VAPNIK. « Support-vector networks ». In : *Machine Learning* 20 (1995), p. 273-297.
- [15] B. SCHÖLKOPF et A. J. SMOLA. *Learning with Kernels*. MIT Press, 2002.
- [16] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009.
- [17] G. MOUNTRAKIS, J. IM et C. OGOLE. « Support vector machines in remote sensing : A review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 66.3 (2011), p. 247-259.
- [18] L. BREIMAN. « Random forests ». In : *Machine Learning* 45.1 (2001), p. 5-32.
- [19] P. O. GISLASON, J. A. BENEDIKTSSON et J. R. SVEINSSON. « Random forests for land cover classification ». In : *Pattern Recognition Letters* 27.4 (2006), p. 294-300.
- [20] M. BELGIU et L. DRĂGUȚ. « Random forest in remote sensing : A review of applications and future directions ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 114 (2016), p. 24-31.

Références II

- [21] R. M. HARALICK, K. SHANMUGAM et I. DINSTEIN. « Textural features for image classification ». In : *IEEE Transactions on Systems, Man, and Cybernetics* 3.6 (1973), p. 610-621.
- [22] R. M. HARALICK et L. G. SHAPIRO. « Image segmentation techniques ». In : *Computer Vision, Graphics, and Image Processing* 29.1 (1985), p. 100-132.
- [23] T. BLASCHKE. « Object based image analysis for remote sensing ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 65.1 (2010), p. 2-16.
- [24] R. AZENCOTT et C. GRAFFIGNE. « Non-supervised segmentation using multi-level Markov random fields ». In : *11th IAPR International Conference on Pattern Recognition, Vol. III, Conference C : Image, Speech and Signal Analysis*. 1992, p. 201-204.
- [25] X. LI, H. ZHAO, X. HAN et al. « A survey of semantic segmentation ». In : *arXiv preprint arXiv:1412.7062* (2014).
- [26] G. CSURKA, D. LARLUS, F. PERRONNIN et F. MEYLAN. « What is a good semantic segmentation model ? A survey ». In : *International Journal of Computer Vision* (2023).
- [27] L. BRUZZONE et S. B. SERPICO. « An iterative technique for the detection of land-cover transitions in multitemporal remote-sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* 35.4 (1997), p. 858-867.
- [28] L. BRUZZONE et S. B. SERPICO. « A neural-statistical approach to multitemporal and multisource remote-sensing image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* 37.3 (1999), p. 1350-1359.
- [29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* 5.1 (2012), p. 1-155.
- [30] S. KIRKPATRICK. « Optimization by simulated annealing : Quantitative studies ». In : *Journal of Statistical Physics* 34.5 (1984), p. 975-986.
- [31] Y. BOYKOV, O. VEKSLER et R. ZABIH. « Fast approximate energy minimization via graph cuts ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 23.11 (2001), p. 1222-1239.
- [32] K. TANAKA, J.-i. INOUE et D. M. TITTERINGTON. « Loopy belief propagation and probabilistic image processing ». In : *2003 IEEE XIII Workshop on Neural Networks for Signal Processing*. 2003, p. 329-338.
- [33] H. DERIN et H. ELLIOTT. « Modeling and segmentation of noisy and textured images using Gibbs random fields ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 9.1 (1987), p. 39-55.
- [34] G. MOSER et S. B. SERPICO. « Combining support vector machines and Markov random fields in an integrated framework for contextual image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* 51.5 (2013), p. 2734-2752.
- [35] J. LAFFERTY, A. MCCALLUM et F. PEREIRA. « Conditional random fields : Probabilistic models for segmenting and labeling sequence data ». In : *International Conference on Machine Learning (ICML)*. 2001.
- [36] P. KRÄHENBÜHL et V. KOLTUN. « Efficient inference in fully connected CRFs with Gaussian edge potentials ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2011.

Références III

- [37] S. ZHENG, S. JAYASUMANA, B. ROMERA-PAREDES et al. « Conditional random fields as recurrent neural networks ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2015.
- [38] M. PASTORINO, A. MONTALDO, L. FRONDA et al. « Multisensor and multiresolution remote sensing image classification through a causal hierarchical Markov framework and decision tree ensembles ». In : *Remote Sensing* 13.5 (2021), p. 849.
- [39] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Semantic segmentation of remote-sensing images through fully convolutional neural networks and hierarchical probabilistic graphical models ». In : *IEEE Transactions on Geoscience and Remote Sensing* 60 (2022), p. 1-16.
- [40] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « CRFNet : A deep convolutional network to learn the potentials of a CRF for the semantic segmentation of remote sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2024).
- [41] A. VOISIN, V. A. KRYLOV, G. MOSER et al. « Classification of very high resolution SAR images of urban areas using copulas and texture in a hierarchical Markov random field model ». In : *IEEE Geoscience and Remote Sensing Letters* 10.1 (2013), p. 96-100.
- [42] S. DELLEPIANE, D. D. GIUSTO, S. B. SERPICO et G. VERNAZZA. « SAR image recognition by integration of intensity and textural information ». In : *International Journal of Remote Sensing* 12.9 (1991), p. 1915-1932.
- [43] J. SERRA. *Image Analysis and Mathematical Morphology*. Academic Press, 1982.
- [44] P. SOILLE. *Morphological Image Analysis*. Springer, 2003.
- [45] J. A. BENEDIKTSSON, J. A. PALMASON et J. R. SVEINSSON. « Classification of hyperspectral data from urban areas based on extended morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* 43.3 (2005), p. 480-491.
- [46] M. DALLA MURA, J. A. BENEDIKTSSON, B. WASKE et L. BRUZZONE. « Morphological attribute profiles for the analysis of very high resolution images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2010).
- [47] M. FAUVEL, J. A. BENEDIKTSSON, J. CHANUSSOT et J. R. SVEINSSON. « Spectral and spatial classification of hyperspectral data using SVMs and morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* 46.11 (2008), p. 3804-3814.
- [48] A. PLAZA, J. A. BENEDIKTSSON, J. W. BOARDMAN et al. « Recent advances in techniques for hyperspectral image processing ». In : *Remote Sensing of Environment* 113 (2009), S110-S122.
- [49] G. CAMPS-VALLS, D. TUIA, L. BRUZZONE et J. A. BENEDIKTSSON. « Advances in hyperspectral image classification ». In : *IEEE Signal Processing Magazine* (2014).
- [50] Y. TARABALKA, J. A. BENEDIKTSSON et J. CHANUSSOT. « Spectral-spatial classification of hyperspectral imagery based on partitional clustering techniques ». In : *IEEE Transactions on Geoscience and Remote Sensing* 47.8 (2009), p. 2973-2987.
- [51] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Communications on Pure and Applied Mathematics* 42.5 (1989), p. 577-685.

Références IV

- [52] C. SAMSON, L. BLANC-FÉRAUD, G. AUBERT et J. ZERUBIA. « A variational model for image classification and restoration ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 22.5 (2000), p. 460-472.
- [53] M. KASS, A. WITKIN et D. TERZOPOULOS. « Snakes : Active contour models ». In : *International Journal of Computer Vision* 1.4 (1988), p. 321-331.
- [54] S. OSHER et J. A. SETHIAN. « Fronts propagating with curvature-dependent speed : Algorithms based on Hamilton–Jacobi formulations ». In : *Journal of Computational Physics* 79.1 (1988), p. 12-49.
- [55] T. F. CHAN et L. A. VESE. « Active contours without edges ». In : *IEEE Transactions on Image Processing* 10.2 (2001), p. 266-277.
- [56] A. KRIZHEVSKY, I. SUTSKEVER et G. E. HINTON. « ImageNet classification with deep convolutional neural networks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2012.
- [57] Y. CHEN, Z. LIN, X. ZHAO et al. « Deep learning-based classification of hyperspectral data ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 7.6 (2014), p. 2094-2107.
- [58] M. CASTELLUCCIO, G. POGGI, C. SANSONE et L. VERDOLIVA. « Land use classification in remote sensing images by convolutional neural networks ». In : *arXiv preprint arXiv:1508.00092* (2015).
- [59] J. LONG, E. SHELHAMER et T. DARRELL. « Fully convolutional networks for semantic segmentation ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, p. 3431-3440.
- [60] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Probabilistic graphical models meet deep learning for semantic segmentation : Mathematical connections and recent developments ». In : *IEEE Signal Processing Magazine* 43.2 (2026), p. 51-63.
- [61] O. RONNEBERGER, P. FISCHER et T. BROX. « U-Net : Convolutional networks for biomedical image segmentation ». In : *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2015, p. 234-241.
- [62] N. AUDEBERT, B. LE SAUX et S. LEFÈVRE. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 140 (2018), p. 20-32.
- [63] Z. ZHANG, Q. LIU et Y. WANG. « Road extraction by deep residual U-Net ». In : *IEEE Geoscience and Remote Sensing Letters* 15.5 (2018), p. 749-753.
- [64] F. ISIKDOGAN, A. C. BOVIK et P. PASSALACQUA. « Surface water mapping by deep learning ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 10.11 (2017), p. 4909-4918.
- [65] K. HE, X. ZHANG, S. REN et J. SUN. « Deep residual learning for image recognition ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, p. 770-778.
- [66] L.-C. CHEN, G. PAPANDREOU, F. SCHROFF et H. ADAM. « Rethinking atrous convolution for semantic image segmentation ». In : *arXiv preprint arXiv:1706.05587* (2017).

Références V

- [67] L.-C. CHEN, Y. ZHU, G. PAPANDREOU et al. « Encoder-decoder with atrous separable convolution for semantic image segmentation ». In : *European Conference on Computer Vision (ECCV)*. 2018, p. 801-818.
- [68] T.-Y. LIN, P. DOLLÁR, R. GIRSHICK et al. « Feature pyramid networks for object detection ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, p. 2117-2125.
- [69] L. MA, Y. LIU, X. ZHANG et al. « Deep learning in remote sensing applications : A meta-analysis and review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 152 (2019), p. 166-177.
- [70] A. VASWANI, N. SHAZEER, N. PARMAR et al. « Attention is all you need ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2017.
- [71] A. DOSOVITSKIY et al. « An image is worth 16x16 words : Transformers for image recognition at scale ». In : *International Conference on Learning Representations (ICLR)*. 2021.
- [72] Z. LIU, Y. LIN, Y. CAO et al. « Swin transformer : Hierarchical vision transformer using shifted windows ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2021, p. 10012-10022.
- [73] E. XIE, W. WANG, Z. YU et al. « SegFormer : Simple and efficient design for semantic segmentation with transformers ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2021.
- [74] K. HE, X. CHEN, S. XIE et al. « Masked autoencoders are scalable vision learners ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, p. 16000-16009.
- [75] C. BROWN, M. KAZMIERSKI, V. PASQUARELLA et al. « AlphaEarth Foundations : An embedding field model for accurate and efficient global mapping from sparse label data ». In : *arXiv preprint arXiv:2507.22291* (2025).
- [76] Y. CONG, S. KHANNA, C. MENG et al. « SatMAE : Pre-training transformers for temporal and multi-spectral satellite imagery ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.
- [77] J. JAKUBIK et al. « Foundation models for geospatial artificial intelligence ». In : *arXiv preprint arXiv:2310.18660* (2023).
- [78] D. WANG, J. ZHANG, B. DU et al. « An empirical study of remote sensing pretraining ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2023).
- [79] A. KIRILLOV, E. MINTUN, N. RAVI et al. « Segment anything ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2023, p. 4015-4026.