

Segmentation sémantique en télédétection



D'après l'article de synthèse [1]

Josiane ZERUBIA

Centre Inria d'Université Côte d'Azur, équipe AYANA

en collaboration avec Martina PASTORINO et Gabriele MOSER

Università di Genova, DITEN

[1] M. PASTORINO et al. « Segmentation sémantique en télédétection ». In : *Traitement du Signal et des Images (TSI), GRETSI (2027)*. Également disponible comme rapport de recherche Inria RR-9631, <https://inria.hal.science/hal-05742224> (sept. 2026)

1. Introduction
2. Classification statistique pixel à pixel
3. Méthodes discriminantes et à noyaux
4. Méthodes d'ensemble
5. Classification contextuelle
6. Modèles markoviens et bayésiens
7. Méthodes spectro-spatiales
8. Méthodes variationnelles
9. Apprentissage profond
10. Transformers et modèles de fondation
11. Conclusion


01 Introduction





De l'image à la carte thématique

- Associer à **chaque pixel** une étiquette d'un ensemble prédéfini de classes sémantiques [2] [3] [4] : problème étudié depuis des décennies sous les noms de *classification supervisée*, *pixel à pixel*, *contextuelle*
- Produit une **carte dense**, à distinguer de la segmentation qui partitionne en régions homogènes *sans* leur associer de signification
- En télédétection : transformer les observations satellitaires en **cartes d'occupation et d'utilisation du sol**



(a) image aérienne



(b) carte de segmentation

Jeu de données Zeebruges, comité technique IADF de l'IEEE GRSS ; images et vérité terrain : Académie royale militaire belge et ONERA.

[2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973

[3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978

[4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986



Ce qui distingue la télédétection

- ▶ **Capteurs** hétérogènes : optique, radar à synthèse d'ouverture (RSO), LiDAR
- ▶ **Résolutions spatiales** très variables, acquisitions à **différentes dates**, **plusieurs modalités** combinées
- ▶ **Scènes géographiques complexes**, dont les propriétés varient selon les régions, les saisons et les conditions d'acquisition
- ▶ Conséquence : l'évolution du domaine **n'est pas** une simple **adaptation** des avancées de la **vision par ordinateur**
- ▶ C'est une convergence entre **reconnaissance statistique des formes**, **traitement du signal et des images**, **modélisation probabiliste**, **morphologie mathématique**, **géométrie stochastique**, **analyse orientée objet** et, récemment, **apprentissage profond**



Formalisation et fil directeur

$$I : \Omega \longrightarrow \mathbb{R}^d \quad \text{puis} \quad f : \Omega \longrightarrow \mathcal{C}$$

- ▶ Ω : domaine spatial ; d : nombre de variables (bande panchromatique, bandes multi- ou hyperspectrales, polarisations RSO, mesures LiDAR, indices spectraux, modèles numériques de terrain...)
- ▶ $\mathcal{C}$: ensemble fini des classes sémantiques
- ▶ **Fil directeur de l'exposé** : une intégration progressive de niveaux croissants de contexte



02

Classification statistique pixel à pixel



Les premières approches (années 1970–1980)

- ▶ Landsat (optique) et SeaSat (radar) créent le besoin de cartes d'occupation du sol automatiques [5] [6] [7]
- ▶ Chaque pixel est un vecteur d'observations $\mathbf{x} = (x_1, \dots, x_d)^T$: réponses radiométriques, intensités RSO, indices, données auxiliaires [2]

$$\hat{\omega} = \arg \max_{\omega_i} P(\omega_i | \mathbf{x})$$

- ▶ Sous hypothèse gaussienne multivariée : **classifieur MAP**, « maximum a posteriori », référence pendant plusieurs décennies [3] [4] [8]

[2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973

[3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978

[4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986

[5] R. SCHOWENGERDT. *Remote Sensing : Models and Methods for Image Processing*. Academic Press, 2007

[6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003

[7] F. ULABY et D. LONG. *Microwave Radar and Radiometric Remote Sensing*. 1^{re} éd. Artech House, 2015

[8] P. M. MATHER. *Computer Processing of Remotely-Sensed Images*. Wiley, 2004



Deux limites structurelles

- ▶ **Malédiction de la dimension** (phénomène de Hughes, décrit dès 1968) [9]
 - plus de variables spectrales $\neq$ meilleures performances lorsque le nombre d'échantillons d'apprentissage reste limité
 - les signatures spectrales seules ne suffisent pas
- ▶ **Hypothèse d'indépendance des observations**
 - chaque pixel est décidé isolément, sans exploiter son voisinage
 - or les objets géographiques sont fortement corrélés spatialement : parcelle agricole, forêt, zone urbaine, réseau routier
- ▶ Conséquence : **cartes bruitées**, d'autant plus que la résolution spatiale augmente


[9] G. HUGHES. « On the mean accuracy of statistical pattern recognizers ». In : *IEEE Transactions on Information Theory* (1968)



Le résultat : des cartes bruitées



(a) image IKONOS, 4 m, fausses couleurs



(b) classification pixel à pixel

Image IKONOS, 4 m, 3 bandes, fausses couleurs (infrarouge voisin, rouge, bleu) ; carte de segmentation [13].

- La décision ne dépend plus seulement de la radiométrie d'un pixel : il faut son **environnement spatial**
- Le problème cesse d'être une classification spectrale pour devenir un problème d'**interprétation spatiale des scènes** [10] [11] [12]

[10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (1984)

[11] J. BESAG. « On the statistical analysis of dirty pictures ». In : *Journal of the Royal Statistical Society : Series B* (1986)

[12] A. H. S. SOLBERG et al. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Transactions on Geoscience and Remote Sensing* (1996)

[13] G. MOSER et al. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proceedings of the IEEE* (2013)

03

Méthodes discriminantes et à noyaux



Estimer la frontière plutôt que la distribution

- ▶ À partir de la fin des années 1990 : estimer **directement les frontières de décision** plutôt que la loi des observations
- ▶ Réponse à deux difficultés : hypothèses gaussiennes **peu réalistes**, **dimension élevée** des données
- ▶ **Machines à vecteurs de support (SVM)**, issues de la théorie de l'apprentissage statistique [14] [15]
 - principe de **maximisation de la marge** entre classes
 - **excellente généralisation** même lorsque le nombre d'échantillons d'apprentissage est faible devant la dimension

[14] V. N. VAPNIK. *Statistical Learning Theory*. Wiley, 1998

[15] C. CORTES et V. VAPNIK. « Support-vector networks ». In : *Machine Learning* (1995)

Noyaux : la non-linéarité sans perdre la convexité

- ▶ Les méthodes à noyaux étendent le cadre aux problèmes **non linéaires** tout en conservant une **formulation convexe** [16]
- ▶ Années 2000 : les SVM deviennent l'un des classifieurs **les plus utilisés** en télédétection : multispectral, hyperspectral, multisources
- ▶ Développement de **noyaux adaptés aux observations géospatiales** [17] [18]
- ▶ **Mais** : les SVM améliorent la *fonction de décision*, pas la représentation : appliqués aux vecteurs d'observations, ils restent des classifieurs **pixel à pixel**
- ▶ Deux directions de recherche évoluent alors en parallèle : *nouveaux classifieurs* et *représentations spatiales plus riches*

[16] B. SCHÖLKOPF et A. J. SMOLA. *Learning with Kernels*. MIT Press, 2002

[17] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009

[18] G. MOUNTRAKIS et al. « Support vector machines in remote sensing : A review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2011)

04

Méthodes d'ensemble





Forêts aléatoires

- ▶ Combiner plusieurs classifieurs pour gagner en robustesse et en généralisation : **apprentissage d'ensemble**
- ▶ **Forêts aléatoires** : arbres de décision appris sur des sous-ensembles aléatoires *des observations et des variables*, agrégés par vote majoritaire [19]
- ▶ Limitent le surapprentissage tout en modélisant des relations non linéaires
- ▶ En pratique : peu de réglages, robustes au bruit, supportent un grand nombre de variables, fournissent des mesures d'**importance des variables**
- ▶ Multispectral et hyperspectral [20], puis occupation du sol, détection de changements, fusion multisources [21]

[19] L. BREIMAN. « Random forests ». In : *Machine Learning* (2001)

[20] P. O. GISLASON et al. « Random forests for land cover classification ». In : *Pattern Recognition Letters* (2006)

[21] M. BELGIU et L. DRĂGUȚ. « Random forest in remote sensing : A review of applications and future directions ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2016)



Bilan de l'ère « pixel »

- ▶ Méthodes discriminantes et d'ensemble : gains nets **sur le classifieur**
- ▶ Elles restent **indépendantes de la représentation**, qu'elle soit spectrale, texturale, morphologique ou spectro-spatiale
- ▶ La limite fondamentale demeure : **l'organisation spatiale de la scène n'est pas prise en compte explicitement**
- ▶ Deux réponses complémentaires vont structurer la suite :
 - régulariser les **étiquettes** : contextuel, markovien, variationnel (sections 5, 6 et 8)
 - enrichir les **descripteurs** : spectro-spatial, orienté objet (section 7)

05

Classification contextuelle





Trois niveaux de contexte

- ▶ Dès les années 1980–1990 : un pixel a davantage de chances d'appartenir à la classe de ses voisins immédiats qu'à une autre [4]
- ▶ **Contexte local** : interactions entre pixels voisins, fenêtres de taille limitée [23]
- ▶ **Contexte régional** : texture, forme, taille, homogénéité des régions segmentées ; annonce l'analyse orientée objet [24]
- ▶ **Contexte global** : organisation générale de la scène, relations entre objets, connaissances a priori sur leur disposition
- ▶ Hiérarchie structurante jusqu'aux architectures profondes contemporaines [25] [26]

[4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986

[23] R. M. HARALICK et L. G. SHAPIRO. « Image segmentation techniques ». In : *Computer Vision, Graphics, and Image Processing* (1985)

[24] T. BLASCHKE. « Object based image analysis for remote sensing ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2010)

[25] R. AZENCOTT et C. GRAFFIGNE. « Non-supervised segmentation using multi-level Markov random fields ». In : *11th IAPR International Conference on Pattern Recognition, Vol. III, Conference C : Image, Speech and Signal Analysis*. 1992


[26] G. CSURKA et al. « What is a good semantic segmentation model ? A survey ». In : *International Journal of Computer Vision* (2023)




L'apport mesurable du contexte



(a) image IKONOS



(b) pixel à pixel



(c) contextuelle

Image IKONOS, 4 m, 3 bandes, fausses couleurs (infrarouge voisin, rouge, bleu) ; cartes de segmentation [13].

- Gains nets en multispectral, multitemporel et multisources [12] [27] [28]
- Les étiquettes ne sont plus décidées une à une : elles doivent être estimées **conjointement**

[12] A. H. S. SOLBERG et al. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Transactions on Geoscience and Remote Sensing* (1996)

[13] G. MOSER et al. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proceedings of the IEEE* (2013)

[27] L. BRUZZONE et S. B. SERPICO. « An iterative technique for the detection of land-cover transitions in multitemporal remote-sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (1997)

[28] L. BRUZZONE et S. B. SERPICO. « A neural-statistical approach to multitemporal and multisource remote-sensing image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* (1999)

06

Modèles markoviens et bayésiens



Les champs de Markov : la première formalisation

- ▶ Les étiquettes ne sont plus indépendantes : ce sont des variables aléatoires définies sur un **graphe de voisinage** [10] [11] [29]
- ▶ Hypothèses de Markov et équivalence champs de Markov / distributions de Gibbs

$$\hat{Y} = \arg \max_Y P(Y | X) \quad \Longleftrightarrow \quad \hat{Y} = \arg \min_Y U(Y | X)$$

- ▶ X : les observations, Y : les étiquettes à estimer
- ▶ Le théorème de Bayes transforme l'estimation MAP en une **minimisation d'énergie**

[10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (1984)

[11] J. BESAG. « On the statistical analysis of dirty pictures ». In : *Journal of the Royal Statistical Society : Series B* (1986)


[29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* (2012)



Attache aux données + régularisation

$$U(Y | X) = U_d(Y | X) + \beta U_r(Y | X)$$

- ▶ U_d : **attache aux données**, dérivée de la vraisemblance
- ▶ U_r : **régularisation spatiale**, favorise la cohérence entre pixels voisins
- ▶ β : compromis fidélité / régularité
- ▶ Voisinages du 1^{er} ou du 2^d ordre ; les potentiels de clique **pénalisent les changements** de classe entre **pixels adjacents** [29]



Voisinages entre pixels dans une grille et cliques associées [29].

[29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* (2012)



Optimiser : un problème difficile

- ▶ Trouver la configuration optimale est un problème d'optimisation combinatoire difficile $\Rightarrow$ stratégies **sous-optimales**
- ▶ **Modes conditionnels itérés (ICM)**, **recuit simulé** [30], échantillonneur de **Gibbs** [10]
- ▶ **Coupes de graphes** [31], **propagation de croyance avec boucles** [32]
- ▶ Domaines d'application : cohérence spatiale des classifications, segmentation multisource, restauration, détection de changements, fusion optique / radar / LiDAR [12] [33] [34]
- ▶ Au-delà des applications : une **formulation probabiliste générale de la régularisation spatiale**

- [10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (1984)
- [12] A. H. S. SOLBERG et al. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Transactions on Geoscience and Remote Sensing* (1996)
- [30] S. KIRKPATRICK. « Optimization by simulated annealing : Quantitative studies ». In : *Journal of Statistical Physics* (1984)
- [31] Y. BOYKOV et al. « Fast approximate energy minimization via graph cuts ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2001)
- [32] K. TANAKA et al. « Loopy belief propagation and probabilistic image processing ». In : *2003 IEEE XIII Workshop on Neural Networks for Signal Processing*. 2003
- [33] H. DERIN et H. ELLIOTT. « Modeling and segmentation of noisy and textured images using Gibbs random fields ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (1987)
- [34] G. MOSER et S. B. SERPICO. « Combining support vector machines and Markov random fields in an integrated framework for contextual image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2013)



Des MRF aux CRF

- ▶ Les champs conditionnels aléatoires représentent directement $P(Y | X)$ plutôt que la loi jointe [35] : ils facilitent l'usage de **caractéristiques discriminantes complexes**
- ▶ **CRF entièrement connectés** : contours des objets mieux préservés [36]
- ▶ Intégration aux réseaux profonds : modules de raffinement, **couches différentiables** [37] ; cadres markoviens hiérarchiques et CRF appris [38] [39] [40] [41]
- ▶ **L'idée qui traverse le domaine** : une carte doit être compatible avec les observations locales et avec l'organisation spatiale de la scène

- [35] J. LAFFERTY et al. « Conditional random fields : Probabilistic models for segmenting and labeling sequence data ». In : *International Conference on Machine Learning (ICML)*. 2001
- [36] P. KRÄHENBÜHL et V. KOLTUN. « Efficient inference in fully connected CRFs with Gaussian edge potentials ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2011
- [37] S. ZHENG et al. « Conditional random fields as recurrent neural networks ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2015
- [38] M. PASTORINO et al. « Multisensor and multiresolution remote sensing image classification through a causal hierarchical Markov framework and decision tree ensembles ». In : *Remote Sensing* (2021)
- [39] M. PASTORINO et al. « Semantic segmentation of remote-sensing images through fully convolutional neural networks and hierarchical probabilistic graphical models ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2022)
- [40] M. PASTORINO et al. « CRFNet : A deep convolutional network to learn the potentials of a CRF for the semantic segmentation of remote sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2024)
- [41] A. VOISIN et al. « Classification of very high resolution SAR images of urban areas using copulas and texture in a hierarchical Markov random field model ». In : *IEEE Geoscience and Remote Sensing Letters* (2013)

07

Méthodes spectro-spatiales





Enrichir la représentation, pas les étiquettes

- ▶ Les modèles contextuels régularisent les **étiquettes** ; ici on enrichit les **descripteurs** avant la classification [6]
- ▶ Idées : **montée en résolution** spatiale et spectrale des capteurs
 - une même classe présente une forte variabilité spectrale
 - des objets différents ont parfois des signatures très proches
- ▶ Texture, forme, taille, organisation spatiale et relations de voisinage deviennent **aussi discriminantes que les valeurs spectrales** [42]

[6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003

[42] S. DELLEPIANE et al. « SAR image recognition by integration of intensity and textural information ». In : *International Journal of Remote Sensing* (1991)

Morphologie mathématique



érosion




image originale RVB



dilatation

Érosion (à gauche) et dilatation (à droite) de l'image satellite originale RVB (au centre).

- Statistiques locales et descripteurs texturaux [22]
- Opérateurs de **morphologie mathématique** : érosion, dilatation et leurs compositions [43] [44]

[22] R. M. HARALICK et al. « Textural features for image classification ». In : *IEEE Transactions on Systems, Man, and Cybernetics* (1973)

[43] J. SERRA. *Image Analysis and Mathematical Morphology*. Academic Press, 1982

[44] P. SOILLE. *Morphological Image Analysis*. Springer, 2003



Profils morphologiques et profils d'attributs

- ▶ **Profils morphologiques étendus (EMP)** [45] puis **profils d'attributs** [46] : décrire simultanément les propriétés spectrales et la structure spatiale **à plusieurs échelles**
- ▶ Références pour l'hyperspectral et la très haute résolution
- ▶ Associés aux SVM : performances remarquables [17] [47], mais le principe est général (forêts aléatoires, réseaux de neurones. . .)
- ▶ Réduction de dimension, méthodes fondées sur les sous-espaces, fusion multisources [48] [49]
- ▶ Utiliser les **régions segmentées** comme unités d'analyse plutôt que les pixels : cohérence spatiale accrue, bruit réduit [50]

[17] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009

[45] J. A. BENEDIKTSSON et al. « Classification of hyperspectral data from urban areas based on extended morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2005)

[46] M. DALLA MURA et al. « Morphological attribute profiles for the analysis of very high resolution images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2010)

[47] M. FAUVEL et al. « Spectral and spatial classification of hyperspectral data using SVMs and morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2008)

[48] A. PLAZA et al. « Recent advances in techniques for hyperspectral image processing ». In : *Remote Sensing of Environment* (2009)

[49] G. CAMPS-VALLS et al. « Advances in hyperspectral image classification ». In : *IEEE Signal Processing Magazine* (2014)

[50] Y. TARABALKA et al. « Spectral-spatial classification of hyperspectral imagery based on partitional clustering techniques ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2009)

08

Méthodes variationnelles





Segmenter en minimisant une énergie

- ▶ Fin des années 1980, en parallèle des champs de Markov : **pas de loi de probabilité explicite sur les étiquettes**, mais la **recherche de la partition** qui réalise le meilleur compromis entre **fidélité aux observations** et **régularité** [29] [51] [52]
- ▶ **Contours actifs** : les frontières sont des courbes déformables évoluant sous l'action [52] [53]
 - de *forces internes* (régularité du contour)
 - de *forces externes* (dérivées de l'information de l'image)
- ▶ Une représentation **explicite** des contours, et le point de départ d'une large famille de méthodes par minimisation d'énergie

[29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* (2012)

[51] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Communications on Pure and Applied Mathematics* (1989)

[52] C. SAMSON et al. « A variational model for image classification and restoration ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2000)

[53] M. KASS et al. « Snakes : Active contour models ». In : *International Journal of Computer Vision* (1988)



La fonctionnelle de Mumford–Shah

$$E(u, K) = \underbrace{\int_{\Omega} (u - I)^2 dx}_{\text{fidélité aux données}} + \mu \underbrace{\int_{\Omega \setminus K} |\nabla u|^2 dx}_{\text{régularité intra-région}} + \nu \underbrace{|K|}_{\text{complexité des contours}}$$


- ▶ u : image reconstruite, I : image observée, K : ensemble des discontinuités (les contours) [51]
- ▶ $\mu > 0$: douceur de la solution à l'intérieur des régions ; $\nu > 0$: pondération de la mesure des contours
- ▶ Un compromis explicite entre **ajustement aux données** et **régularité de la solution**, principe commun à de nombreuses méthodes de segmentation
- ▶ L'un des modèles variationnels les plus influents en traitement d'images

[51] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Communications on Pure and Applied Mathematics* (1989)



Robustesse numérique et applications

- **Surfaces de niveau** : contours représentés implicitement, changements de topologie gérés automatiquement [54]
- **Modèles régionaux** : statistiques des régions plutôt que gradients seuls, robustes au bruit et au faible contraste [55]
- En télédétection : **segmentation optique haute résolution, restauration, fusion, extraction d'objets ; classification et restauration** unifiées dans une même fonctionnelle [52]
- **Convergence** : bayésien, champs de Markov, variationnel et formulations sur graphes sont différentes expressions d'un même principe : **attache aux données + régularisation**



(a) image SPOT (b) segmentation

(a) image satellitaire SPOT © CNES ; (b) segmentation par la méthode variationnelle de [52].

[52] C. SAMSON et al. « A variational model for image classification and restoration ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2000)

[54] S. OSHER et J. A. SETHIAN. « Fronts propagating with curvature-dependent speed : Algorithms based on Hamilton–Jacobi formulations ». In : *Journal of Computational Physics* (1988)

[55] T. F. CHAN et L. A. VESE. « Active contours without edges ». In : *IEEE Transactions on Image Processing* (2001)

09

Apprentissage profond





2012 : la bascule

- ▶ **AlexNet** démontre une amélioration spectaculaire en classification d'images naturelles [56]
- ▶ On **apprend** des **représentations hiérarchiques** directement à partir des données, sans conception manuelle de descripteurs spectraux, texturaux ou géométriques
- ▶ La performance dépend désormais de la capacité du réseau à apprendre **conjointement** une représentation pertinente *et* la fonction de décision
- ▶ Transposition rapide à la télédétection : représentations plus discriminantes, **transfert** de modèles pré-entraînés sur les grandes bases d'images naturelles [57] [58]
- ▶ Les **approches spectro-spatiales** passent de représentations *conçues* à des représentations *appries*


[56] A. KRIZHEVSKY et al. « ImageNet classification with deep convolutional neural networks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2012

[57] Y. CHEN et al. « Deep learning-based classification of hyperspectral data ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* (2014)

[58] M. CASTELLUCCIO et al. « Land use classification in remote sensing images by convolutional neural networks ». In : *arXiv preprint arXiv :1508.00092* (2015)

Prédiction dense : FCN et encodeur-décodeur

- **FCN** : suppression des couches entièrement connectées au profit d'opérations convolutionnelles $\Rightarrow$ prédiction dense à l'échelle du pixel, apprise de bout en bout [59]
- **U-Net** : encodeur-décodeur dont les *connexions de saut* réinjectent la localisation perdue au sous-échantillonnage, d'où de meilleurs contours et de plus petits objets [61]
- **Applications** : occupation du sol, bâtiments, routes, réseaux hydrographiques [62] [63] [64]



architecture d'un FCN

Appliquée aux images aériennes de la base ISPRS 2D Semantic Labeling Challenge (Potsdam) [60].

- [59] J. LONG et al. « Fully convolutional networks for semantic segmentation ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015
- [60] M. PASTORINO et al. « Probabilistic graphical models meet deep learning for semantic segmentation : Mathematical connections and recent developments ». In : *IEEE Signal Processing Magazine* (2026)
- [61] O. RONNEBERGER et al. « U-Net : Convolutional networks for biomedical image segmentation ». In : *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2015
- [62] N. AUDEBERT et al. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2018)
- [63] Z. ZHANG et al. « Road extraction by deep residual U-Net ». In : *IEEE Geoscience and Remote Sensing Letters* (2018)
- [64] F. ISIKDOGAN et al. « Surface water mapping by deep learning ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* (2017)



Contexte, échelles, modalités

- **Réseaux résiduels** : apprendre des modèles plus profonds en limitant la disparition du gradient [65]
- **DeepLab** : convolutions dilatées et agrégation multi-échelle (ASPP) pour augmenter le champ réceptif *sans* dégrader la résolution des prédictions [66] [67]
- **Pyramides de caractéristiques** : objets de tailles très variables [68], décisif en télédétection où une même scène contient véhicules, bâtiments, parcelles et massifs forestiers
- **Multimodalité** : apprendre des représentations communes à partir de l'optique, du RSO, du LiDAR, des modèles numériques de terrain et de données géographiques auxiliaires [62] [69]

[62] N. AUDEBERT et al. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2018)

[65] K. HE et al. « Deep residual learning for image recognition ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016

[66] L.-C. CHEN et al. « Rethinking atrous convolution for semantic image segmentation ». In : *arXiv preprint arXiv :1706.05587* (2017)

[67] L.-C. CHEN et al. « Encoder-decoder with atrous separable convolution for semantic image segmentation ». In : *European Conference on Computer Vision (ECCV)*. 2018

[68] T.-Y. LIN et al. « Feature pyramid networks for object detection ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017

[69] L. MA et al. « Deep learning in remote sensing applications : A meta-analysis and review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* (2019)

Ce que l'apprentissage profond ne supprime pas

- ▶ Contexte spatial, représentation multi-échelle, fusion de données, hiérarchie des objets : **reformulés** dans un cadre d'apprentissage de bout en bout, non abandonnés
- ▶ Limites persistantes des réseaux convolutifs :
 - annotations pixel à pixel **coûteuses**, particulièrement en télédétection
 - **généralisation** limitée entre capteurs, régions géographiques et modalités d'acquisition
 - difficulté à modéliser les dépendances spatiales à **très longue portée**
- ▶ Ces limites ouvrent la voie aux **mécanismes d'attention**, puis aux **modèles de fondation géospatiaux**

10

Transformers et modèles de fondation





L'attention en segmentation

- ▶ Développés pour le traitement du langage, les « transformers » modélisent directement les relations entre **éléments distants** d'une séquence [70] ; leur adaptation à la vision ouvre une nouvelle étape [71]
- ▶ **Swin Transformer** [72] et **SegFormer** [73] : combiner une représentation *hiérarchique* de l'image et une modélisation *globale* du contexte
- ▶ Particulièrement pertinent en télédétection : l'identification d'un bâtiment, d'une route ou d'une parcelle ne repose pas seulement sur l'apparence locale, mais sur son **organisation au sein de la scène**

[70] A. VASWANI et al. « Attention is all you need ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2017

[71] A. DOSOVITSKIY et al. « An image is worth 16x16 words : Transformers for image recognition at scale ». In : *International Conference on Learning Representations (ICLR)*. 2021

[72] Z. LIU et al. « Swin transformer : Hierarchical vision transformer using shifted windows ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2021

[73] E. XIE et al. « SegFormer : Simple and efficient design for semantic segmentation with transformers ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2021



Apprendre sans annotation


- ▶ L'**apprentissage auto-supervisé** devient un axe majeur de recherche
- ▶ Les **autoencodeurs masqués** montrent qu'il est possible d'apprendre des représentations visuelles riches à partir de grandes quantités de données **non annotées** [74]
- ▶ Réponse directe à un **déséquilibre** propre au domaine :
 - les archives satellitaires sont **abondantes**
 - les annotations pixel à pixel restent **rares et coûteuses**

[74] K. HE et al. « Masked autoencoders are scalable vision learners ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022



Modèles de fondation géospatiaux

- ▶ **Pré-entraînés sur de très grands volumes de données**, puis adaptés : classification, segmentation, détection d'objets et de changements [75] [76] [77] [78] [79]
- ▶ Objectif : des **représentations génériques, transférables** entre capteurs, régions géographiques et applications
- ▶ **Coût** du pré-entraînement (calcul, énergie) ⇒ empreinte environnementale et accessibilité
- ▶ Pas une rupture : les mêmes questions (hétérogénéité, contexte, généralisation) sont désormais **appries** plutôt que **construites**



principe général d'un modèle de fondation géospatial

- [75] C. BROWN et al. « AlphaEarth Foundations : An embedding field model for accurate and efficient global mapping from sparse label data ». In : *arXiv preprint arXiv :2507.22291* (2025)
- [76] Y. CONG et al. « SatMAE : Pre-training transformers for temporal and multi-spectral satellite imagery ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2022
- [77] J. JAKUBIK et al. « Foundation models for generalist geospatial artificial intelligence ». In : *arXiv preprint arXiv :2310.18660* (2023)
- [78] D. WANG et al. « An empirical study of remote sensing pretraining ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2023)
- [79] A. KIRILLOV et al. « Segment anything ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2023

11

Conclusion



Une histoire non linéaire

- ▶ Pas une trajectoire allant simplement des classifieurs statistiques aux réseaux profonds, mais la **convergence de plusieurs familles de méthodes** : classification statistique, méthodes à noyaux, méthodes d'ensemble, modèles contextuels, champs de Markov, méthodes variationnelles, géométrie stochastique, apprentissage profond, modèles de fondation
- ▶ Une lecture unifiée : l'**intégration progressive de niveaux croissants de contexte**



- ▶ Un principe récurrent : **attache aux données + régularisation**, des champs de Markov aux fonctions de perte des réseaux profonds

- ▶ Généralisation géographique
- ▶ Manque d'annotations
- ▶ Fusion optique / radar / LiDAR
- ▶ La segmentation sémantique en télédétection demeure un **domaine ouvert**, à l'intersection du traitement du signal et des images, de la modélisation probabiliste, de la géométrie, de la vision par ordinateur et de l'intelligence artificielle, dans un contexte géospatial
- ▶ Prise en compte de la temporalité
- ▶ Interprétabilité des modèles
- ▶ Robustesse opérationnelle

Merci de votre attention.



Références I

- [1] M. PASTORINO, G. MOSER et J. ZERUBIA. « Segmentation sémantique en télédétection ». In : *Traitement du Signal et des Images (TSI), GRETSI* (2027). Également disponible comme rapport de recherche Inria RR-9631, <https://inria.hal.science/hal-05742224> (sept. 2026).
- [2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973.
- [3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978.
- [4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986.
- [5] R. SCHOWENGERDT. *Remote Sensing : Models and Methods for Image Processing*. Academic Press, 2007.
- [6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003.
- [7] F. ULABY et D. LONG. *Microwave Radar and Radiometric Remote Sensing*. 1^{re} éd. Artech House, 2015.
- [8] P. M. MATHER. *Computer Processing of Remotely-Sensed Images*. Wiley, 2004.
- [9] G. HUGHES. « On the mean accuracy of statistical pattern recognizers ». In : *IEEE Transactions on Information Theory* 14.1 (1968), p. 55-63.
- [10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 6.6 (1984), p. 721-741.
- [11] J. BESAG. « On the statistical analysis of dirty pictures ». In : *Journal of the Royal Statistical Society : Series B* 48.3 (1986), p. 259-302.
- [12] A. H. S. SOLBERG, T. TAXT et A. K. JAIN. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Transactions on Geoscience and Remote Sensing* 34.1 (1996), p. 100-113.
- [13] G. MOSER, S. B. SERPICO et J. A. BENEDIKTSSON. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proceedings of the IEEE* 101.3 (2013), p. 631-651.
- [14] V. N. VAPNIK. *Statistical Learning Theory*. Wiley, 1998.
- [15] C. CORTES et V. VAPNIK. « Support-vector networks ». In : *Machine Learning* 20 (1995), p. 273-297.
- [16] B. SCHÖLKOPF et A. J. SMOLA. *Learning with Kernels*. MIT Press, 2002.
- [17] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009.
- [18] G. MOUNTRAKIS, J. IM et C. OGOLE. « Support vector machines in remote sensing : A review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 66.3 (2011), p. 247-259.
- [19] L. BREIMAN. « Random forests ». In : *Machine Learning* 45.1 (2001), p. 5-32.
- [20] P. O. GISLASON, J. A. BENEDIKTSSON et J. R. SVEINSSON. « Random forests for land cover classification ». In : *Pattern Recognition Letters* 27.4 (2006), p. 294-300.

Références II

- [21] M. BELGIU et L. DRĂGUȚ. « Random forest in remote sensing : A review of applications and future directions ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 114 (2016), p. 24-31.
- [22] R. M. HARALICK, K. SHANMUGAM et I. DINSTEIN. « Textural features for image classification ». In : *IEEE Transactions on Systems, Man, and Cybernetics* 3.6 (1973), p. 610-621.
- [23] R. M. HARALICK et L. G. SHAPIRO. « Image segmentation techniques ». In : *Computer Vision, Graphics, and Image Processing* 29.1 (1985), p. 100-132.
- [24] T. BLASCHKE. « Object based image analysis for remote sensing ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 65.1 (2010), p. 2-16.
- [25] R. AZENCOTT et C. GRAFFIGNE. « Non-supervised segmentation using multi-level Markov random fields ». In : *11th IAPR International Conference on Pattern Recognition, Vol. III, Conference C : Image, Speech and Signal Analysis*. 1992, p. 201-204.
- [26] G. CSURKA, D. LARLUS, F. PERRONNIN et F. MEYLAN. « What is a good semantic segmentation model? A survey ». In : *International Journal of Computer Vision* (2023).
- [27] L. BRUZZONE et S. B. SERPICO. « An iterative technique for the detection of land-cover transitions in multitemporal remote-sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* 35.4 (1997), p. 858-867.
- [28] L. BRUZZONE et S. B. SERPICO. « A neural-statistical approach to multitemporal and multisource remote-sensing image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* 37.3 (1999), p. 1350-1359.
- [29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* 5.1 (2012), p. 1-155.
- [30] S. KIRKPATRICK. « Optimization by simulated annealing : Quantitative studies ». In : *Journal of Statistical Physics* 34.5 (1984), p. 975-986.
- [31] Y. BOYKOV, O. VEKSLER et R. ZABIH. « Fast approximate energy minimization via graph cuts ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 23.11 (2001), p. 1222-1239.
- [32] K. TANAKA, J.-i. INOUE et D. M. TITTERINGTON. « Loopy belief propagation and probabilistic image processing ». In : *2003 IEEE XIII Workshop on Neural Networks for Signal Processing*. 2003, p. 329-338.
- [33] H. DERIN et H. ELLIOTT. « Modeling and segmentation of noisy and textured images using Gibbs random fields ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 9.1 (1987), p. 39-55.
- [34] G. MOSER et S. B. SERPICO. « Combining support vector machines and Markov random fields in an integrated framework for contextual image classification ». In : *IEEE Transactions on Geoscience and Remote Sensing* 51.5 (2013), p. 2734-2752.
- [35] J. LAFFERTY, A. MCCALLUM et F. PEREIRA. « Conditional random fields : Probabilistic models for segmenting and labeling sequence data ». In : *International Conference on Machine Learning (ICML)*. 2001.
- [36] P. KRÄHENBÜHL et V. KOLTUN. « Efficient inference in fully connected CRFs with Gaussian edge potentials ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2011.

Références III

- [37] S. ZHENG, S. JAYASUMANA, B. ROMERA-PAREDES et al. « Conditional random fields as recurrent neural networks ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2015.
- [38] M. PASTORINO, A. MONTALDO, L. FRONDA et al. « Multisensor and multiresolution remote sensing image classification through a causal hierarchical Markov framework and decision tree ensembles ». In : *Remote Sensing* 13.5 (2021), p. 849.
- [39] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Semantic segmentation of remote-sensing images through fully convolutional neural networks and hierarchical probabilistic graphical models ». In : *IEEE Transactions on Geoscience and Remote Sensing* 60 (2022), p. 1-16.
- [40] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « CRFNet : A deep convolutional network to learn the potentials of a CRF for the semantic segmentation of remote sensing images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2024).
- [41] A. VOISIN, V. A. KRYLOV, G. MOSER et al. « Classification of very high resolution SAR images of urban areas using copulas and texture in a hierarchical Markov random field model ». In : *IEEE Geoscience and Remote Sensing Letters* 10.1 (2013), p. 96-100.
- [42] S. DELLEPIANE, D. D. GIUSTO, S. B. SERPICO et G. VERNAZZA. « SAR image recognition by integration of intensity and textural information ». In : *International Journal of Remote Sensing* 12.9 (1991), p. 1915-1932.
- [43] J. SERRA. *Image Analysis and Mathematical Morphology*. Academic Press, 1982.
- [44] P. SOILLE. *Morphological Image Analysis*. Springer, 2003.
- [45] J. A. BENEDIKTSSON, J. A. PALMASON et J. R. SVEINSSON. « Classification of hyperspectral data from urban areas based on extended morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* 43.3 (2005), p. 480-491.
- [46] M. DALLA MURA, J. A. BENEDIKTSSON, B. WASKE et L. BRUZZONE. « Morphological attribute profiles for the analysis of very high resolution images ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2010).
- [47] M. FAUVEL, J. A. BENEDIKTSSON, J. CHANUSSOT et J. R. SVEINSSON. « Spectral and spatial classification of hyperspectral data using SVMs and morphological profiles ». In : *IEEE Transactions on Geoscience and Remote Sensing* 46.11 (2008), p. 3804-3814.
- [48] A. PLAZA, J. A. BENEDIKTSSON, J. W. BOARDMAN et al. « Recent advances in techniques for hyperspectral image processing ». In : *Remote Sensing of Environment* 113 (2009), S110-S122.
- [49] G. CAMPS-VALLS, D. TUIA, L. BRUZZONE et J. A. BENEDIKTSSON. « Advances in hyperspectral image classification ». In : *IEEE Signal Processing Magazine* (2014).
- [50] Y. TARABALKHA, J. A. BENEDIKTSSON et J. CHANUSSOT. « Spectral-spatial classification of hyperspectral imagery based on partitional clustering techniques ». In : *IEEE Transactions on Geoscience and Remote Sensing* 47.8 (2009), p. 2973-2987.
- [51] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Communications on Pure and Applied Mathematics* 42.5 (1989), p. 577-685.

Références IV

- [52] C. SAMSON, L. BLANC-FÉRAUD, G. AUBERT et J. ZERUBIA. « A variational model for image classification and restoration ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 22.5 (2000), p. 460-472.
- [53] M. KASS, A. WITKIN et D. TERZOPOULOS. « Snakes : Active contour models ». In : *International Journal of Computer Vision* 1.4 (1988), p. 321-331.
- [54] S. OSHER et J. A. SETHIAN. « Fronts propagating with curvature-dependent speed : Algorithms based on Hamilton–Jacobi formulations ». In : *Journal of Computational Physics* 79.1 (1988), p. 12-49.
- [55] T. F. CHAN et L. A. VESE. « Active contours without edges ». In : *IEEE Transactions on Image Processing* 10.2 (2001), p. 266-277.
- [56] A. KRIZHEVSKY, I. SUTSKEVER et G. E. HINTON. « ImageNet classification with deep convolutional neural networks ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2012.
- [57] Y. CHEN, Z. LIN, X. ZHAO et al. « Deep learning-based classification of hyperspectral data ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 7.6 (2014), p. 2094-2107.
- [58] M. CASTELLUCCIO, G. POGGI, C. SANSONE et L. VERDOLIVA. « Land use classification in remote sensing images by convolutional neural networks ». In : *arXiv preprint arXiv :1508.00092* (2015).
- [59] J. LONG, E. SHELHAMER et T. DARRELL. « Fully convolutional networks for semantic segmentation ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, p. 3431-3440.
- [60] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Probabilistic graphical models meet deep learning for semantic segmentation : Mathematical connections and recent developments ». In : *IEEE Signal Processing Magazine* 43.2 (2026), p. 51-63.
- [61] O. RONNEBERGER, P. FISCHER et T. BROX. « U-Net : Convolutional networks for biomedical image segmentation ». In : *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*. 2015, p. 234-241.
- [62] N. AUDEBERT, B. LE SAUX et S. LEFÈVRE. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 140 (2018), p. 20-32.
- [63] Z. ZHANG, Q. LIU et Y. WANG. « Road extraction by deep residual U-Net ». In : *IEEE Geoscience and Remote Sensing Letters* 15.5 (2018), p. 749-753.
- [64] F. ISIKDOGAN, A. C. BOVIK et P. PASSALACQUA. « Surface water mapping by deep learning ». In : *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 10.11 (2017), p. 4909-4918.
- [65] K. HE, X. ZHANG, S. REN et J. SUN. « Deep residual learning for image recognition ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, p. 770-778.
- [66] L.-C. CHEN, G. PAPANDREOU, F. SCHROFF et H. ADAM. « Rethinking atrous convolution for semantic image segmentation ». In : *arXiv preprint arXiv :1706.05587* (2017).

Références V

- [67] L.-C. CHEN, Y. ZHU, G. PAPANDREOU et al. « Encoder-decoder with atrous separable convolution for semantic image segmentation ». In : *European Conference on Computer Vision (ECCV)*. 2018, p. 801-818.
- [68] T.-Y. LIN, P. DOLLÁR, R. GIRSHICK et al. « Feature pyramid networks for object detection ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2017, p. 2117-2125.
- [69] L. MA, Y. LIU, X. ZHANG et al. « Deep learning in remote sensing applications : A meta-analysis and review ». In : *ISPRS Journal of Photogrammetry and Remote Sensing* 152 (2019), p. 166-177.
- [70] A. VASWANI, N. SHAZEER, N. PARMAR et al. « Attention is all you need ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2017.
- [71] A. DOSOVITSKIY et al. « An image is worth 16x16 words : Transformers for image recognition at scale ». In : *International Conference on Learning Representations (ICLR)*. 2021.
- [72] Z. LIU, Y. LIN, Y. CAO et al. « Swin transformer : Hierarchical vision transformer using shifted windows ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2021, p. 10012-10022.
- [73] E. XIE, W. WANG, Z. YU et al. « SegFormer : Simple and efficient design for semantic segmentation with transformers ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2021.
- [74] K. HE, X. CHEN, S. XIE et al. « Masked autoencoders are scalable vision learners ». In : *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022, p. 16000-16009.
- [75] C. BROWN, M. KAZMIERSKI, V. PASQUARELLA et al. « AlphaEarth Foundations : An embedding field model for accurate and efficient global mapping from sparse label data ». In : *arXiv preprint arXiv :2507.22291* (2025).
- [76] Y. CONG, S. KHANNA, C. MENG et al. « SatMAE : Pre-training transformers for temporal and multi-spectral satellite imagery ». In : *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.
- [77] J. JAKUBIK et al. « Foundation models for generalist geospatial artificial intelligence ». In : *arXiv preprint arXiv :2310.18660* (2023).
- [78] D. WANG, J. ZHANG, B. DU et al. « An empirical study of remote sensing pretraining ». In : *IEEE Transactions on Geoscience and Remote Sensing* (2023).
- [79] A. KIRILLOV, E. MINTUN, N. RAVI et al. « Segment anything ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2023, p. 4015-4026.



Crédits des figures

- Image aérienne et carte de segmentation : jeu de données *Zeebruges*, comité technique d'analyse d'image et de fusion de données (IADF) de l'IEEE GRSS ; images et données de vérité terrain fournies par l'Académie royale militaire belge et l'ONERA (Laboratoire aérospatial français).
- Image satellitaire IKONOS, 4 m, 3 bandes, composition en fausses couleurs (infrarouge voisin, rouge, bleu) ; cartes de segmentation pixel à pixel et contextuelle [13].
- Voisinages du premier et du second ordre dans une grille, et cliques associées [29].
- Érosion et dilatation d'une image satellite RVB.
- Image satellitaire SPOT © CNES ; carte de segmentation obtenue par la méthode variationnelle de [52].
- Architecture d'un FCN appliqué aux images aériennes de la base ISPRS *2D Semantic Labeling Challenge* (Potsdam) [60].
- Principe général d'un modèle de fondation géospatial.

[13] G. MOSER et al. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proceedings of the IEEE* (2013)

[29] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Foundations and Trends in Signal Processing* (2012)

[52] C. SAMSON et al. « A variational model for image classification and restoration ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2000)

[60] M. PASTORINO et al. « Probabilistic graphical models meet deep learning for semantic segmentation : Mathematical connections and recent developments ». In : *IEEE Signal Processing Magazine* (2026)