

# Segmentation sémantique en télédétection



GRETSI 2027, session historique [1]

Josiane ZERUBIA

Centre Inria d'Université Côte d'Azur, équipe AYANA

en collaboration avec Martina PASTORINO et Gabriele MOSER

Università di Genova, DITEN


---

[1] M. PASTORINO et al. « Segmentation sémantique en télédétection ». In : *Traitement du Signal et des Images (TSI), GRETSI* (). Also available as Inria RR-9631 <https://inria.hal.science/hal-05742224> (sept. 2026)

1. Introduction
2. Du pixel au contexte
3. Modèles markoviens et bayésiens
4. Représentations spectro-spatiales et variationnelles
5. Apprentissage profond et modèles de fondation
6. Défis ouverts

## De l'image à la carte thématique

- Associer à **chaque pixel** une étiquette d'un ensemble prédéfini de classes sémantiques [2] [3] [4] : problème étudié depuis des décennies sous les noms de *classification supervisée*, *pixel à pixel*, *contextuelle*
- Produit une **carte dense**, à distinguer de la segmentation qui partitionne en régions homogènes *sans* leur associer de signification
- En télédétection : transformer les observations satellitaires en **cartes d'occupation et d'utilisation du sol**



(a) image aérienne



(b) carte de segmentation

Jeu de données Zeebruges, comité technique IADF de l'IEEE GRSS ; images et vérité terrain : Académie royale militaire belge et ONERA.

[2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973

[3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978

[4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986



## Ce qui distingue la télédétection

- ▶ **Capteurs** hétérogènes : optique, radar à synthèse d'ouverture (RSO), LiDAR.
- ▶ **Résolutions** spatiales et spectrales variables ; acquisitions **multitemporelles** et **multimodales**.
- ▶ **Scènes géographiques complexes**, dont les propriétés varient selon les régions, les saisons et les conditions d'acquisition.
- ▶ Le domaine n'est donc pas une simple adaptation de la vision par ordinateur : il combine **reconnaissance statistique**, **traitement du signal**, **modélisation probabiliste** et **apprentissage profond**.

$$I : \Omega \longrightarrow \mathbb{R}^d \quad \text{puis} \quad f : \Omega \longrightarrow \mathcal{C}$$

- ▶  $\Omega$  : domaine spatial ;  $d$  : variables issues des bandes spectrales, polarisations RSO, mesures LiDAR, indices, MNT, etc.
- ▶  $\mathcal{C}$  : ensemble fini des classes sémantiques.
- ▶ L'histoire du domaine peut se lire comme une **intégration progressive** de l'information spectrale, spatiale, contextuelle, puis multimodale.





## Les premières approches : pixel à pixel

- ▶ À la fin des années 1970 : Landsat (optique) et SeaSat (radar) créent le besoin de cartes d'occupation du sol automatiques [5] [6] [7]
- ▶ Chaque pixel est un vecteur d'observations  $\mathbf{x} = (x_1, \dots, x_d)^T$  : réponses radiométriques, intensités RSO, indices, données auxiliaires [2].

$$\hat{\omega} = \arg \max_{\omega_i} P(\omega_i | \mathbf{x})$$


- ▶ Sous hypothèse gaussienne multivariée : **classifieur MAP**, « maximum a posteriori », référence pendant plusieurs décennies [3] [4] [8]

- [2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973
- [3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978
- [4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986
- [5] R. SCHOWENGERDT. *Remote Sensing : Models and Methods for Image Processing*. Academic Press, 2007
- [6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003
- [7] F. ULABY et D. LONG. *Microwave Radar and Radiometric Remote Sensing*. 1<sup>re</sup> éd. Artech House, 2015
- [8] P. M. MATHER. *Computer Processing of Remotely-Sensed Images*. Wiley, 2004



## Deux limites : dimension et indépendance

- ▶ **Malédiction de la dimension** (phénomène de Hughes) [9] : plus de variables ne garantit pas de meilleures performances lorsque peu d'échantillons sont disponibles.
- ▶ **Hypothèse d'indépendance des observations** : chaque pixel est décidé isolément, sans exploiter son voisinage or les objets géographiques sont fortement corrélés spatialement : parcelle agricole, forêt, zone urbaine, réseau routier
- ▶ Conséquence : **cartes bruitées**, d'autant plus que la résolution spatiale augmente



Classification pixel à pixel : effet « poivre et sel » [13]

[9] G. HUGHES. « On the mean accuracy of statistical pattern recognizers ». In : *IEEE Trans. Inf. Theory* (1968)

[13] G. MOSER et al. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proc. IEEE* (2013)



## Méthodes discriminantes et d'ensemble

- ▶ À partir de la fin des années 1990 : estimer **directement les frontières de décision**, plutôt que la loi des observations.
- ▶ **SVM** : maximisation de la marge ; bonne généralisation en grande dimension [14] [15] [17] [18].
- ▶ **Noyaux** : non-linéarité sans perdre la convexité ; nombreux développements pour les observations géospatiales [16].
- ▶ **Forêts aléatoires** : vote d'arbres de décision appris sur des sous-ensembles aléatoires ; robustesse, peu de réglages, importance des variables [19] [20].
- ▶ Mais ces méthodes restent des classifieurs **essentiellement pixel à pixel** lorsqu'elles sont appliquées aux observations locales.

[14] V. N. VAPNIK. *Statistical Learning Theory*. Wiley, 1998

[15] C. CORTES et V. VAPNIK. « Support-vector networks ». In : *Machine Learn.* (1995)

[16] B. SCHÖLKOPF et A. J. SMOLA. *Learning with Kernels*. MIT Press, 2002

[17] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009

[18] G. MOUNTRAKIS et al. « Support vector machines in remote sensing : A review ». In : *ISPRS J. Photogram. Remote Sens.* (2011)

[19] L. BREIMAN. « Random forests ». In : *Machine Learning* (2001)


[20] P. O. GISLASON et al. « Random forests for land cover classification ». In : *Pattern Recognit. Lett.* (2006)




## L'apport du contexte spatial



(a) image IKONOS



(b) pixel à pixel



(c) contextuelle

Image IKONOS, 4 m, 3 bandes, fausses couleurs ; cartes de segmentation [13].

- En télédétection, les objets géographiques présentent une **forte cohérence spatiale** : parcelles, forêts, zones urbaines, réseaux routiers.
- Les étiquettes doivent être estimées **conjointement**, pas pixel par pixel.

[4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986

[haralick1985image] haralick1985image

[12] A. H. S. SOLBERG et al. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Trans. Geosci. Remote Sens.* (1996)

[13] G. MOSER et al. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proc. IEEE* (2013)

## Les champs de Markov : première formalisation

- ▶ Les étiquettes deviennent des variables aléatoires définies sur un **graphe de voisinage** [10] [11] [22].
- ▶ Sous les hypothèses de Markov et l'équivalence avec les distributions de Gibbs, l'estimation MAP devient une **minimisation d'énergie**.

$$\hat{Y} = \arg \max_Y P(Y | X) \quad \Longleftrightarrow \quad \hat{Y} = \arg \min_Y U(Y | X)$$

- ▶  $X$  : observations ;  $Y$  : carte d'étiquettes à estimer.
- ▶ Les MRF fournissent un cadre général pour relier données locales et cohérence spatiale.

[10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* (1984)

[11] J. BESAG. « On the statistical analysis of dirty pictures ». In : *J. Royal Stat. Soc. : Series B* (1986)


[22] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Found. Trends Signal Process.* (2012)



## Attache aux données + régularisation

$$U(Y | X) = U_d(Y | X) + \beta U_r(Y | X)$$

- ▶  $U_d$  : **attache aux données**, dérivée de la vraisemblance.
- ▶  $U_r$  : **régularisation spatiale**, favorise la cohérence entre pixels voisins.
- ▶  $\beta$  : compromis fidélité / régularité.
- ▶ Voisinages du 1<sup>er</sup> ou du 2<sup>d</sup> ordre ; les potentiels de clique **pénalisent les changements** de classe entre **pixels adjacents** [22]



Voisinages entre pixels dans une grille et cliques associées [22].



## Optimisation et usages des MRF

- ▶ Trouver la configuration optimale est un problème d'optimisation combinatoire difficile.
- ▶ Stratégies : **ICM**, **recuit simulé** [23], échantillonneur de **Gibbs** [10], **coupes de graphes** [24], propagation de croyance avec boucles [25].
- ▶ Applications : classification contextuelle, segmentation multisource, restauration, détection de changements, fusion optique / radar / LiDAR [12] [26] [27].
- ▶ Au-delà des applications : une **formulation probabiliste générale** de la régularisation spatiale.

- [10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* (1984)
- [12] A. H. S. SOLBERG et al. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Trans. Geosci. Remote Sens.* (1996)
- [23] S. KIRKPATRICK. « Optimization by simulated annealing : Quantitative studies ». In : *J. Stat. Phys.* (1984)
- [24] Y. BOYKOV et al. « Fast approximate energy minimization via graph cuts ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* (2001)
- [25] K. TANAKA et al. « Loopy belief propagation and probabilistic image processing ». In : *IEEE NNISP*. 2003
- [26] H. DERIN et H. ELLIOTT. « Modeling and segmentation of noisy and textured images using Gibbs random fields ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* (1987)
- [27] G. MOSER et S. B. SERPICO. « Combining support vector machines and Markov random fields in an integrated framework for contextual image classification ». In : *IEEE Trans. Geosci. Remote Sens.* (2013)



## Des MRF aux CRF : un pont vers le profond

- ▶ Les champs conditionnels aléatoires représentent directement  $P(Y | X)$  plutôt que la loi jointe [28] : ils facilitent l'usage de **caractéristiques discriminantes complexes**.
- ▶ **CRF entièrement connectés** : contours des objets mieux préservés [29].
- ▶ Intégration aux réseaux profonds : modules de raffinement, **couches différentiables** [30] ; cadres markoviens hiérarchiques et CRF appris [31] [32] [33] [34].
- ▶ **L'idée qui traverse le domaine** : une carte doit être compatible avec les observations locales et avec l'organisation spatiale de la scène.

[28] J. LAFFERTY et al. « Conditional random fields : Probabilistic models for segmenting and labeling sequence data ». In : *ICML*. 2001

[29] P. KRÄHENBÜHL et V. KOLTUN. « Efficient inference in fully connected CRFs with Gaussian edge potentials ». In : *NeurIPS*. 2011

[30] S. ZHENG et al. « Conditional random fields as recurrent neural networks ». In : *IEEE ICCV*. 2015

[31] M. PASTORINO et al. « Multisensor and multiresolution remote sensing image classification through a causal hierarchical Markov framework and decision tree ensembles ». In : *Remote Sensing* (2021)

[32] M. PASTORINO et al. « Semantic segmentation of remote-sensing images through fully convolutional neural networks and hierarchical probabilistic graphical models ». In : *IEEE Trans. Geosci. Remote Sens.* (2022)

[33] M. PASTORINO et al. « CRFNet : A deep convolutional network to learn the potentials of a CRF for the semantic segmentation of remote sensing images ». In : *IEEE Trans. Geosci. Remote Sens.* (2024)

[34] A. VOISIN et al. « Classification of very high resolution SAR images of urban areas using copulas and texture in a hierarchical Markov random field model ». In : *IEEE Geosci. Remote Sens. Lett.* (2013)

## Enrichir la représentation, pas seulement les étiquettes

- ▶ Les modèles contextuels régularisent les **étiquettes** ; les méthodes spectro-spatiales enrichissent les **descripteurs** avant la classification [6]
- ▶ Avec l'augmentation des résolutions, les signatures radiométriques seules deviennent insuffisantes.
- ▶ Texture, forme, taille, organisation spatiale et relations de voisinage deviennent **aussi discriminantes que les valeurs spectrales** [35].
- ▶ Cette logique prépare les représentations multi-échelles apprises par les réseaux profonds [21].

[6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003

[21] T. BLASCHKE. « Object based image analysis for remote sensing ». In : *ISPRS J. Photogram. Remote Sens.* (2010)

[35] S. DELLEPIANE et al. « SAR image recognition by integration of intensity and textural information ». In : *International Journal of Remote Sensing* (1991)

# Morphologie mathématique et profils multi-échelles



érosion




image originale RVB



dilatation

Érosion et dilatation de l'image satellite originale RVB.

- ▶ Opérateurs : érosion, dilatation, ouvertures, fermetures [36] [37].
- ▶ **Profils morphologiques étendus** et **profils d'attributs** décrivent forme, taille et contraste à plusieurs échelles [38] [39] [40].

[36] J. SERRA. *Image Analysis and Mathematical Morphology*. Academic Press, 1982

[37] P. SOILLE. *Morphological Image Analysis*. Springer, 2003

[38] J. A. BENEDIKTSSON et al. « Classification of hyperspectral data from urban areas based on extended morphological profiles ». In : *IEEE Trans. Geosci. Remote Sens.* (2005)

[39] M. DALLA MURA et al. « Morphological attribute profiles for the analysis of very high resolution images ». In : *IEEE Trans. Geosci. Remote Sens.* (2010)

[40] M. FAUVEL et al. « Spectral and spatial classification of hyperspectral data using SVMs and morphological profiles ». In : *IEEE Trans. Geosci. Remote Sens.* (2008)

## Méthodes variationnelles : régulariser la solution

- ▶ Démarche complémentaire : intégrer directement la cohérence spatiale dans la formulation du problème.
- ▶ La segmentation est formulée comme une **minimisation d'énergie** combinant fidélité aux observations et régularité spatiale ou géométrique [42].

$$E(u) = \text{fidélité aux données} + \lambda \text{ régularité spatiale/géométrique}$$

- ▶ La fonctionnelle de **Mumford-Shah** est l'un des modèles fondateurs [41].
- ▶ Les principes de compromis données/régularité, multi-échelle et fusion seront repris sous des formes apprises dans l'apprentissage profond.


[41] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Commun. Pure Appl. Math.* (1989)

[42] C. SAMSON et al. « A variational model for image classification and restoration ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* (2000)



# Apprendre profond

- ▶ 2012 la bascule : **AlexNet** démontre une amélioration spectaculaire en classification d'images naturelles [43]
- ▶ Changement : apprendre conjointement les représentations et la fonction de décision directement à partir des données.
- ▶ **FCN** : prédiction dense à l'échelle du pixel.
- ▶ **U-Net** : connexions de saut pour restituer l'information spatiale.
- ▶ **DeepLab** : convolutions dilatées et représentations multi-échelles pour élargir le champ réceptif.




Architecture FCN appliquée à Potsdam

- [43] A. KRIZHEVSKY et al. « ImageNet classification with deep convolutional neural networks ». In : *NeurIPS*. 2012
- [44] J. LONG et al. « Fully convolutional networks for semantic segmentation ». In : *IEEE/CVF CVPR*. 2015
- [46] O. RONNEBERGER et al. « U-Net : Convolutional networks for biomedical image segmentation ». In : *MICCAI*. 2015
- [48] L.-C. CHEN et al. « Encoder-decoder with atrous separable convolution for semantic image segmentation ». In : *ECCV*. 2018
- [47] N. AUDEBERT et al. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS J. Photogram. Remote Sens.* (2018)
- [49] L. MA et al. « Deep learning in remote sensing applications : A meta-analysis and review ». In : *ISPRS J. Photogram. Remote Sens.* (2019)

# Transformers, auto-supervisé et modèles de fondation

- ▶ Les CNN restent limités par le besoin en annotations et par la modélisation des dépendances à longue portée.
- ▶ Les mécanismes d'**attention** et les transformers représentent mieux les interactions entre régions distantes [50] [51].
- ▶ L'**auto-supervision** exploite de grands volumes d'images satellitaires non annotées pour apprendre des représentations transférables [52].
- ▶ Objectif : passer d'un modèle spécialisé à des représentations **générales, multimodales et transférables (modèles de fondation géospatiaux)** [53].



Principe d'un modèle de fondation géospatial

[50] A. VASWANI et al. « Attention is all you need ». In : *NeurIPS*. 2017

[51] A. DOSOVITSKIY et al. « An image is worth 16x16 words : Transformers for image recognition at scale ». In : *ICLR*. 2021

[52] K. HE et al. « Masked autoencoders are scalable vision learners ». In : *IEEE/CVF CVPR*. 2022

[53] A. XIAO et al. « Foundation Models for Remote Sensing and Earth Observation : A Survey ». In : *IEEE Geosci. Remote Sens. Mag.* (2025)

## Défis ouverts

- ▶ **Généralisation** entre régions, saisons, capteurs et résolutions.
- ▶ **Manque d'annotations** : coût élevé des vérités terrain, déséquilibre entre classes, labels imparfaits.
- ▶ **Fusion multimodale** : optique, RSO, LiDAR, séries temporelles et données auxiliaires.
- ▶ **Robustesse** : changements de distribution, nuages, bruit, artefacts, événements rares.
- ▶ **Interprétabilité** : comprendre et contrôler les décisions de modèles de plus en plus grands.



## Conclusion : une histoire non linéaire

- ▶ Pas une trajectoire allant simplement des classifieurs statistiques aux réseaux profonds, mais la **convergence de plusieurs familles de méthodes** : classification statistique, méthodes à noyaux, méthodes d'ensemble, modèles contextuels, champs de Markov, méthodes variationnelles, géométrie stochastique, apprentissage profond, modèles de fondation
- ▶ Une lecture unifiée : l'**intégration progressive de niveaux croissants de contexte**



- ▶ Un principe récurrent : **attache aux données + régularisation**, des champs de Markov aux fonctions de perte des réseaux profonds

*Merci de votre attention.*



# Références

- [1] M. PASTORINO, G. MOSER et J. ZERUBIA. « Segmentation sémantique en télédétection ». In : *Traitement du Signal et des Images (TSI), GRETSI* (). Also available as Inria RR-9631 <https://inria.hal.science/hal-05742224> (sept. 2026).
- [2] R. O. DUDA et P. E. HART. *Pattern Classification and Scene Analysis*. Wiley, 1973.
- [3] P. H. SWAIN et S. M. DAVIS. *Remote Sensing : The Quantitative Approach*. McGraw-Hill, 1978.
- [4] J. A. RICHARDS. *Remote Sensing Digital Image Analysis*. Springer, 1986.
- [5] R. SCHOWENGERDT. *Remote Sensing : Models and Methods for Image Processing*. Academic Press, 2007.
- [6] D. A. LANDGREBE. *Signal Theory Methods in Multispectral Remote Sensing*. John Wiley & Sons, Ltd, 2003.
- [7] F. ULABY et D. LONG. *Microwave Radar and Radiometric Remote Sensing*. 1<sup>re</sup> éd. Artech House, 2015.
- [8] P. M. MATHER. *Computer Processing of Remotely-Sensed Images*. Wiley, 2004.
- [9] G. HUGHES. « On the mean accuracy of statistical pattern recognizers ». In : *IEEE Trans. Inf. Theory* 14.1 (1968), p. 55-63.
- [10] S. GEMAN et D. GEMAN. « Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* 6.6 (1984), p. 721-741.
- [11] J. BESAG. « On the statistical analysis of dirty pictures ». In : *J. Royal Stat. Soc. : Series B* 48.3 (1986), p. 259-302.
- [12] A. H. S. SOLBERG, T. TAXT et A. K. JAIN. « A Markov random field model for classification of multisource satellite imagery ». In : *IEEE Trans. Geosci. Remote Sens.* 34.1 (1996), p. 100-113.
- [13] G. MOSER, S. B. SERPICO et J. A. BENEDIKTSSON. « Land-cover mapping by Markov modeling of spatial-contextual information in very-high-resolution remote sensing images ». In : *Proc. IEEE* 101.3 (2013), p. 631-651.
- [14] V. N. VAPNIK. *Statistical Learning Theory*. Wiley, 1998.
- [15] C. CORTES et V. VAPNIK. « Support-vector networks ». In : *Machine Learn.* 20 (1995), p. 273-297.
- [16] B. SCHÖLKOPF et A. J. SMOLA. *Learning with Kernels*. MIT Press, 2002.
- [17] G. CAMPS-VALLS et L. BRUZZONE. *Kernel Methods for Remote Sensing Data Analysis*. Wiley, 2009.
- [18] G. MOUNTRAKIS, J. IM et C. OGOLE. « Support vector machines in remote sensing : A review ». In : *ISPRS J. Photogram. Remote Sens.* 66.3 (2011), p. 247-259.
- [19] L. BREIMAN. « Random forests ». In : *Machine Learning* 45.1 (2001), p. 5-32.
- [20] P. O. GISLASON, J. A. BENEDIKTSSON et J. R. SVEINSSON. « Random forests for land cover classification ». In : *Pattern Recognit. Lett.* 27.4 (2006), p. 294-300.
- [21] T. BLASCHKE. « Object based image analysis for remote sensing ». In : *ISPRS J. Photogram. Remote Sens.* 65.1 (2010), p. 2-16.
- [22] Z. KATO et J. ZERUBIA. « Markov random fields in image segmentation ». In : *Found. Trends Signal Process.* 5.1 (2012), p. 1-155.
- [23] S. KIRKPATRICK. « Optimization by simulated annealing : Quantitative studies ». In : *J. Stat. Phys.* 34.5 (1984), p. 975-986.

## Références II

- [24] Y. BOYKOV, O. VEKSLER et R. ZABIH. « Fast approximate energy minimization via graph cuts ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* 23.11 (2001), p. 1222-1239.
- [25] K. TANAKA, J.-i. INOUE et D. M. TITTERINGTON. « Loopy belief propagation and probabilistic image processing ». In : *IEEE NNISP.* 2003, p. 329-338.
- [26] H. DERIN et H. ELLIOTT. « Modeling and segmentation of noisy and textured images using Gibbs random fields ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* 9.1 (1987), p. 39-55.
- [27] G. MOSER et S. B. SERPICO. « Combining support vector machines and Markov random fields in an integrated framework for contextual image classification ». In : *IEEE Trans. Geosci. Remote Sens.* 51.5 (2013), p. 2734-2752.
- [28] J. LAFFERTY, A. MCCALLUM et F. PEREIRA. « Conditional random fields : Probabilistic models for segmenting and labeling sequence data ». In : *ICML.* 2001.
- [29] P. KRÄHENBÜHL et V. KOLTUN. « Efficient inference in fully connected CRFs with Gaussian edge potentials ». In : *NeurIPS.* 2011.
- [30] S. ZHENG, S. JAYASUMANA, B. ROMERA-PAREDES et al. « Conditional random fields as recurrent neural networks ». In : *IEEE ICCV.* 2015.
- [31] M. PASTORINO, A. MONTALDO, L. FRONDA et al. « Multisensor and multiresolution remote sensing image classification through a causal hierarchical Markov framework and decision tree ensembles ». In : *Remote Sensing* 13.5 (2021), p. 849.
- [32] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Semantic segmentation of remote-sensing images through fully convolutional neural networks and hierarchical probabilistic graphical models ». In : *IEEE Trans. Geosci. Remote Sens.* 60 (2022), p. 1-16.
- [33] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « CRFNet : A deep convolutional network to learn the potentials of a CRF for the semantic segmentation of remote sensing images ». In : *IEEE Trans. Geosci. Remote Sens.* (2024).
- [34] A. VOISIN, V. A. KRYLOV, G. MOSER et al. « Classification of very high resolution SAR images of urban areas using copulas and texture in a hierarchical Markov random field model ». In : *IEEE Geosci. Remote Sens. Lett.* 10.1 (2013), p. 96-100.
- [35] S. DELLEPIANE, D. D. GIUSTO, S. B. SERPICO et G. VERNAZZA. « SAR image recognition by integration of intensity and textural information ». In : *International Journal of Remote Sensing* 12.9 (1991), p. 1915-1932.
- [36] J. SERRA. *Image Analysis and Mathematical Morphology.* Academic Press, 1982.
- [37] P. SOILLE. *Morphological Image Analysis.* Springer, 2003.
- [38] J. A. BENEDIKTSSON, J. A. PALMASON et J. R. SVEINSSON. « Classification of hyperspectral data from urban areas based on extended morphological profiles ». In : *IEEE Trans. Geosci. Remote Sens.* 43.3 (2005), p. 480-491.
- [39] M. DALLA MURA, J. A. BENEDIKTSSON, B. WASKE et L. BRUZZONE. « Morphological attribute profiles for the analysis of very high resolution images ». In : *IEEE Trans. Geosci. Remote Sens.* (2010).
- [40] M. FAUVEL, J. A. BENEDIKTSSON, J. CHANUSSOT et J. R. SVEINSSON. « Spectral and spatial classification of hyperspectral data using SVMs and morphological profiles ». In : *IEEE Trans. Geosci. Remote Sens.* 46.11 (2008), p. 3804-3814.

# Références III

- [41] D. MUMFORD et J. SHAH. « Optimal approximations by piecewise smooth functions and associated variational problems ». In : *Commun. Pure Appl. Math.* 42.5 (1989), p. 577-685.
- [42] C. SAMSON, L. BLANC-FÉRAUD, G. AUBERT et J. ZERUBIA. « A variational model for image classification and restoration ». In : *IEEE Trans. Pattern Anal. Mach. Intell.* 22.5 (2000), p. 460-472.
- [43] A. KRIZHEVSKY, I. SUTSKEVER et G. E. HINTON. « ImageNet classification with deep convolutional neural networks ». In : *NeurIPS*. 2012.
- [44] J. LONG, E. SHELHAMER et T. DARRELL. « Fully convolutional networks for semantic segmentation ». In : *IEEE/CVF CVPR*. 2015, p. 3431-3440.
- [45] M. PASTORINO, G. MOSER, S. B. SERPICO et J. ZERUBIA. « Probabilistic graphical models meet deep learning for semantic segmentation : Mathematical connections and recent developments ». In : *IEEE Signal Process. Mag.* 43.2 (2026), p. 51-63.
- [46] O. RONNEBERGER, P. FISCHER et T. BROX. « U-Net : Convolutional networks for biomedical image segmentation ». In : *MICCAI*. 2015, p. 234-241.
- [47] N. AUDEBERT, B. LE SAUX et S. LEFÈVRE. « Beyond RGB : Very high resolution urban remote sensing with multimodal deep networks ». In : *ISPRS J. Photogram. Remote Sens.* 140 (2018), p. 20-32.
- [48] L.-C. CHEN, Y. ZHU, G. PAPANDREOU et al. « Encoder-decoder with atrous separable convolution for semantic image segmentation ». In : *ECCV*. 2018, p. 801-818.
- [49] L. MA, Y. LIU, X. ZHANG et al. « Deep learning in remote sensing applications : A meta-analysis and review ». In : *ISPRS J. Photogram. Remote Sens.* 152 (2019), p. 166-177.
- [50] A. VASWANI, N. SHAZEER, N. PARMAR et al. « Attention is all you need ». In : *NeurIPS*. 2017.
- [51] A. DOSOVITSKIY et al. « An image is worth 16x16 words : Transformers for image recognition at scale ». In : *ICLR*. 2021.
- [52] K. HE, X. CHEN, S. XIE et al. « Masked autoencoders are scalable vision learners ». In : *IEEE/CVF CVPR*. 2022, p. 16000-16009.
- [53] A. XIAO, W. XUAN, J. WANG et al. « Foundation Models for Remote Sensing and Earth Observation : A Survey ». In : *IEEE Geosci. Remote Sens. Mag.* 13.4 (2025), p. 297-324.
- [54] A. KIRILLOV, E. MINTUN, N. RAVI et al. « Segment anything ». In : *IEEE ICCV*. 2023, p. 4015-4026.